



TESIS DE MAESTRÍA

Clasificación de los dígitos escritos en los telegramas de las elecciones legislativas en Santa Fe mediante técnicas de adaptación de dominio

Autor:

Ing. Franco LIANZA

Director:

Dr. Leandro BUGNON

30 de julio de 2023

UNIVERSIDAD AUSTRAL

Resumen

Facultad de Ingeniería

Clasificación de los dígitos escritos en los telegramas de las elecciones legislativas en Santa Fe mediante técnicas de adaptación de dominio

En Argentina, las elecciones se realizan cada 2 años, excepto las presidenciales que ocurren cada 4 años. El proceso de conteo de votos en los centros de cómputo requiere una cantidad considerable de personal para ser eficiente y rápido. Para abordar este desafío, se propone la digitalización automática de los telegramas de votación. Sin embargo, la clasificación de dígitos manuscritos presenta dificultades debido a la variabilidad en la escritura de los mismos y el sesgo existente en los conjuntos de datos disponibles.

A lo largo de la tesis, se entrenaron modelos de reconocimiento de dígitos que son robustos frente a los cambios en los datos mediante la adaptación de dominio. Se utilizaron los telegramas oficiales de las elecciones legislativas de Santa Fe en 2021 para construir un conjunto de datos y se realizaron experimentos junto a otro conjunto de datos público de dígitos. Se probaron redes neuronales LeNet5 y ResNet18 entrenadas mediante las siguientes técnicas de adaptación de dominio: red neuronal adversaria de dominio, adaptación de dominio adversaria discriminativa, penalización espectral en lotes, discrepancia de disparidad de margen y normalización de características adaptativa. El objetivo es encontrar el modelo más resistente al sesgo y que mejor generalice en diversos contextos.

El mejor modelo obtenido es una ResNet18 con normalización de características adaptativa, que logra clasificar de manera robusta los dígitos en las elecciones estudiadas mediante la adaptación de dominio. Los resultados obtenidos tienen implicaciones importantes en la automatización de los procesos electorales, mejorando la eficiencia y transparencia de las elecciones. La digitalización efectiva de los telegramas permite acelerar y precisar el conteo de votos, reduciendo la posibilidad de errores humanos y aumentando la confianza en los procesos electorales.

Índice general

Resumen	III
1. Introducción	1
1.1. Contexto	1
1.2. Motivación	2
1.3. Objetivos	4
1.4. Estructura de la tesis	4
2. Marco teórico	7
2.1. Reconocimiento de dígitos	7
2.2. Redes neuronales	8
2.2.1. Redes densas	9
2.2.2. Redes convolucionales	10
2.2.3. Arquitecturas	13
LeNet	14
ResNet	14
2.3. Aprendizaje por transferencia	15
2.4. Adaptación de dominio	16
2.4.1. Red neuronal adversaria de dominio	17
2.4.2. Adaptación de dominio adversaria discriminativa	19
2.4.3. Penalización espectral en lotes	21
2.4.4. Discrepancia de disparidad de margen	22
2.4.5. Normalización de características adaptativa	23
3. Metodología	25
3.1. Descripción de los datos	25
3.2. Extracción de dígitos de los telegramas	25
3.2.1. Alineación de los telegramas	26
3.2.2. Extracción de la grilla de votos	26
3.2.3. Detección de líneas de la grilla de votos	27
3.2.4. Segmentación de dígitos	29
3.3. Análisis del conjunto de datos	31
3.4. Diseño experimental	33
3.4.1. Metodología de entrenamiento	34
3.4.2. Selección y optimización del modelo	34
3.5. Métricas de evaluación	35
3.5.1. Métricas de clasificación	35
Tasa de acierto	35
F_1	35
Intersección sobre unión	36

3.5.2. Métricas de adaptación	37
Distancia A	37
Discrepancia de Medias Máxima	37
4. Análisis de resultados	39
4.1. Análisis de métricas	39
4.2. Análisis de los espacios latentes	42
4.2.1. LeNet	43
4.2.2. ResNet	46
4.3. Análisis de errores	48
5. Conclusiones	51
5.1. Trabajos Futuros	52
A. Anexo: Telegramas	53
A.1. Ejemplo de telegrama	54
A.2. Ejemplo de telegrama mal cargado	55
A.3. Ejemplo de telegrama con números sin espacio entre ellos	56
A.4. Ejemplo de telegrama con caracteres distintos a números	57
A.5. Ejemplo de telegrama ceros a la izquierda de la cantidad de votos	58
Bibliografía	59

Índice de figuras

2.1.	Red neuronal densa	10
2.2.	Operador <i>convolución</i>	11
2.3.	Operador <i>maxpool</i>	12
2.4.	Red neuronal convolucional	13
2.5.	Arquitectura de una LeNet5	14
2.6.	Esquema de una GAN	18
2.7.	Esquema de <i>DANN</i>	18
2.8.	Esquema de <i>ADDA</i>	20
2.9.	Esquema de <i>DANN+BSP</i>	21
2.10.	Esquema de <i>MDD</i>	22
2.11.	Representación de características aprendidas de una CNN	23
2.12.	Esquema de <i>AFN</i>	24
3.1.	Alineación de un telegrama	26
3.2.	Grilla de votos detectada	27
3.3.	Proyecciones de los ejes de la grilla de votos	28
3.4.	Segmentación de la grilla detectada	28
3.5.	Primer renglón extraído de la grilla de votos	29
3.6.	Dígitos después del desenfoque gaussiano	29
3.7.	Máscara obtenida al aplicar umbral adaptativo	29
3.8.	Máscara con componentes conectados detectados	29
3.9.	Dígitos delimitados	30
3.10.	Dígitos detectados en el primer bloque de votos	30
3.11.	Dígitos en formato cuadrado	30
3.12.	Histogramas de proporciones mínimas y máximas de píxeles blancos por dígito	32
3.13.	Conjunto de datos TDS	33
3.14.	Ejemplos de distribuciones de dominios	37
4.1.	Distribución de cantidad de aciertos por telegrama por LeNet5	41
4.2.	Distribución de cantidad de aciertos por telegrama por ResNet18	42
4.3.	Representación UMAP de las características aprendidas de los modelos LeNet5	44
4.4.	Representación UMAP de las características aprendidas de los modelos ResNet18	47
4.5.	Histogramas de IoU por modelo	49

Índice de cuadros

1.1.	Precisión que se obtiene al aplicar un modelo LeNet5 entrenado con otros conjuntos de datos de dígitos.	3
3.1.	Ejemplo del conjunto de datos generado	31
3.2.	Estadísticos descriptivos de los dígitos	32
3.3.	Rango de hiperparámetros optimizados	34
4.1.	Métricas de los experimentos realizados	40
4.2.	IoU y aciertos por modelo	41

Capítulo 1

Introducción

1.1. Contexto

En Argentina se celebran elecciones cada 2 años a excepción de las presidenciales que se realizan cada 4 años. Existen, principalmente, tres tipos de elecciones:

- Elecciones nacionales, para elegir a las autoridades federales del país: el Poder Ejecutivo, constituido por el Presidente y el vicepresidente y el Congreso Nacional, formado por Senadores y Diputados.
- Elecciones provinciales y de la Ciudad de Buenos Aires o locales, para elegir a las autoridades de cada provincia: los poderes ejecutivos de las provincias y sus legislaturas.
- Elecciones municipales, regidas por las leyes y procedimientos de cada provincia.

El proceso para emitir el sufragio en Argentina puede variar según la elección, pero en general se sigue un procedimiento similar en todas ellas¹. Primero, los ciudadanos habilitados para votar deben presentarse en su lugar de votación el día de las elecciones, que suele ser un domingo, y dirigirse a la mesa correspondiente según su número de documento. Una vez allí, se les solicita que presenten su documento de identidad para que las autoridades de mesa puedan verificar su identidad y comprobar que se encuentran en el padrón electoral. Luego, los votantes reciben una boleta con los candidatos y partidos políticos que participan en la elección. Los ciudadanos deben dirigirse a una cabina de votación para emitir su voto en secreto. Allí, pueden seleccionar la boleta completa de un partido o candidato, o elegir diferentes candidatos de diferentes partidos. Una vez que han realizado su elección, deben doblar la boleta y dirigirse a la urna donde depositarán su voto. Al finalizar la jornada de votación, las autoridades de mesa llevan a cabo el recuento de votos. Esto implica el conteo manual de los votos emitidos y la elaboración de una planilla en la que se detallan los votos obtenidos por cada candidato o partido político. Esta planilla es firmada por todas las autoridades de mesa y se digitalizan para ser enviadas al correo argentino. La mayoría se escanea en las escuelas y el restante lo escanea el propio correo. Una vez en el centro de cómputo, un grupo de personas se encarga de contabilizar los votos

¹<https://www.cippec.org/como-se-cuentan-los-votos/>.

utilizando un sistema informático. En primer lugar, se digitaliza la información de las planillas recibidas para que pueda ser procesada por el sistema. Luego, se lleva a cabo un proceso de validación para verificar que los datos sean correctos y no haya errores. Una vez que se ha completado el proceso de digitalización y validación, se obtiene el resultado final de la elección y se anuncia públicamente el candidato o partido político ganador. Es importante destacar que, aunque se utilice la boleta única electrónica, en la mayoría de los procesos electorales siempre se realiza un conteo manual de respaldo para asegurar la transparencia y la integridad de los resultados. De esta manera, se verifica que el conteo realizado por el sistema informático sea consistente con el conteo manual y se evita cualquier posibilidad de fraude o error.

El proceso de conteo de votos en un centro de cómputo requiere de una gran cantidad de personas para poder llevarse a cabo de manera eficaz y rápida. Sin embargo, esta solución resulta altamente ineficiente en términos de tiempo y costos. En las elecciones legislativas del 2021 en Argentina, se destinaron alrededor de \$17.000 millones de pesos para el proceso electoral, de los cuales alrededor de \$4.000 millones de pesos fueron utilizados para el pago de salarios del personal encargado del centro de cómputo².

1.2. Motivación

Digitalizar los telegramas de manera automática supondrá un ahorro considerable en el presupuesto de las elecciones, agilizará la obtención de los resultados y aportará transparencia al proceso en general. Es posible entrenar un modelo de clasificación de dígitos a un costo extremadamente menor al actual y utilizarlo al momento de la contabilización de los votos.

Contar con una digitalización automática permitirá bajar los costos debido a que se necesitará un grupo menor de personas en el centro de cómputo. Además, el trabajo a realizar será más simple, ya que solo constará del proceso de validación.

La digitalización automática de los telegramas de votación es una iniciativa que busca mejorar la eficiencia del proceso electoral, reducir los costos y aumentar la transparencia en las elecciones. Actualmente, el proceso de conteo de votos se realiza manualmente y puede ser un proceso largo y laborioso.

Utilizando la tecnología de procesamiento de imágenes para contar automáticamente los votos de los telegramas, es posible reducir la cantidad de personal requerido en el centro de cómputo. Esto podría ahorrar costos en términos de recursos humanos y materiales, ya que el personal necesario para el conteo manual de votos sería menor. Además, se reduciría la posibilidad de error humano, lo que mejoraría la precisión del proceso de conteo de votos.

²<https://www.cronista.com/economia-politica/Elecciones-legislativas-2021-cuanto-mas-se-gastara-por-el-coronavirus-segun-el-Presupuesto-20201004-0006.html>.

Por otro lado, la digitalización automática de los telegramas también aceleraría el proceso de conteo de votos y permitiría que los resultados se obtengan más rápidamente. Esto podría ayudar a reducir la ansiedad y la tensión que a menudo rodean los resultados electorales, así como mejorar la transparencia del proceso en general. Al contar con resultados electorales precisos y rápidos, se puede mejorar la confianza en el sistema electoral y en las instituciones democráticas.

Es importante destacar que este proceso no requiere de una gran inversión. De hecho, es posible entrenar modelos de clasificación de dígitos a un costo extremadamente menor que el actual, utilizando técnicas de aprendizaje automático para identificar y clasificar los números individuales que componen los votos en los telegramas. Esto permitiría la implementación de un sistema de conteo de votos automatizado con un menor costo y una mayor precisión.

La clasificación de números manuscritos es un problema que puede parecer ya resuelto gracias al conjunto de datos MNIST y al trabajo pionero de LeCun en 1998. Sin embargo, no se puede subestimar la complejidad de este problema. Cada año, cambian las personas que llenan los telegramas de las elecciones y, por lo tanto, las características de los números escritos a mano pueden variar. Esto puede generar un *corrimiento de dominio* o *data drift*, lo que significa que un modelo entrenado en un conjunto de datos estático como MNIST puede presentar una mala clasificación de los dígitos escritos a mano en las elecciones.

Cuando los dominios de entrenamiento y aplicación son diferentes, se debe a que existe un sesgo en los datos. Las técnicas de entrenamiento tradicionales asumen que, aunque existe un sesgo, este será el mismo entre el origen y el destino. Sin embargo, cuando este supuesto no se cumple, las predicciones del modelo pueden verse afectadas negativamente. El cuadro 1.1 ilustra un ejemplo de cómo la precisión del modelo puede degradarse cuando se aplica a un conjunto de datos diferente al que se entrenó. Incluso en conjuntos de datos similares, como MNIST y USPS, la disminución en la precisión de los modelos es notable.

CUADRO 1.1: Precisión que se obtiene al aplicar un modelo LeNet5 entrenado con otros conjuntos de datos de dígitos.

Validación	MNIST	USPS	SVHN
Entrenamiento			
MNIST 	99.17 %	78.08 %	31.50 %
USPS 	57.10 %	95.42 %	26.94 %
SVHN 	61.92 %	64.28 %	89.52 %

En conclusión, debido a que la escritura de los números en los telegramas puede variar de elección en elección y a que los datos de entrenamiento no son suficientes para una clasificación precisa en este contexto, se necesita recurrir a técnicas más complejas de entrenamiento que permitan al modelo adaptarse a diferentes dominios. La adaptación de dominio es una técnica que busca reducir el efecto del sesgo de los datos y hacer que el modelo sea más robusto ante las variaciones en la escritura de los números. En la actualidad, no existen trabajos publicados que comparan diferentes técnicas de adaptación de dominio para la digitalización de telegramas en Argentina, lo que sugiere una oportunidad para investigar y desarrollar modelos más efectivos para este propósito.

1.3. Objetivos

El objetivo general de esta tesis es clasificar los dígitos de los votos en las elecciones legislativas de la provincia de Santa Fe del año 2021 mediante adaptación de dominio de forma que el modelo generalice y no dependa de un etiquetado de los datos. El enfoque se centrará en explorar y comparar diferentes técnicas de adaptación de dominio con el fin de lograr un modelo robusto que pueda generalizar en diferentes contextos y escenarios electorales. Con esto se contribuye a mejorar la transparencia y eficiencia en los procesos electorales en Argentina y sentar las bases para el desarrollo de soluciones similares para el resto de las provincias y la nación.

Los objetivos específicos para lograr el objetivo planteado son los siguientes:

- Armar el proceso de extracción, transformación y carga (ETL) de los telegramas, con el propósito de segmentar y limpiar de manera efectiva los dígitos. Los datos utilizados serán obtenidos de fuentes oficiales del estado argentino³. En el anexo A.1 se adjunta un ejemplo de uno de ellos.
- Entrenar distintas arquitecturas de redes convolucionales mediante técnicas de adaptación de dominio.
- Analizar y evaluar las métricas relevantes para seleccionar el mejor modelo.
- Detectar oportunidades de mejora en el proceso eleccionario respecto al diseño de los telegramas.

1.4. Estructura de la tesis

Esta tesis se encuentra organizado con la siguiente estructura:

³<https://op.elecciones.gob.ar/telegramas/generales2021/>.

- Capítulo 2: Marco teórico del reconocimiento de dígitos, redes neuronales, aprendizaje por transferencia y adaptación de dominio.
- Capítulo 3: Metodología del trabajo realizado sobre los telegramas de las elecciones de Santa Fe. Proceso de extracción, transformación y limpieza de los mismos. Diseño experimental y métricas de evaluación.
- Capítulo 4: Análisis de resultados. Análisis de métricas, espacios latentes obtenidos y errores observados.
- Capítulo 5: Conclusiones del trabajo, mejoras planteadas y futuras investigaciones.

El código generado para realizar esta tesis se encuentra disponible en el repositorio Lianza (2023).

Capítulo 2

Marco teórico

Este capítulo del marco teórico tiene como objetivo presentar una visión general de la bibliografía relevante al objetivo de la tesis. En la primera sección, se explorará la historia del reconocimiento de dígitos por parte de las computadoras y las técnicas desarrolladas. Posteriormente, se brindará un breve resumen de la evolución de las redes neuronales, con especial atención en las redes densas y convolucionales, y sus conceptos básicos. La sección siguiente se enfocará en el aprendizaje por transferencia de las redes neuronales, sus capacidades y limitaciones. Finalmente, se profundizará en la adaptación de dominio y se explicarán las distintas técnicas utilizadas en el trabajo.

2.1. Reconocimiento de dígitos

El reconocimiento de caracteres por parte de las computadoras ha sido un campo de investigación activo durante varias décadas. Una de las primeras investigaciones en este campo se centró en cómo las neuronas del cerebro procesan y reconocen información visual.

En 1959, Hubel y Wiesel comenzaron a investigar la percepción visual en el cerebro de los gatos. Descubrieron que las neuronas en la corteza visual primaria del cerebro de los gatos respondían a estímulos visuales específicos, como líneas y bordes. Además, identificaron dos tipos de células en la corteza visual primaria: células simples y células complejas. Las células simples respondían a estímulos visuales específicos, como barras de luz en una dirección particular, mientras que las células complejas respondían a estímulos visuales más complejos, como patrones en movimiento. En 1981 recibieron el Premio Nobel de Fisiología o Medicina por su trabajo en el procesamiento visual del cerebro.

Inspirado por el trabajo de Hubel y Wiesel, en 1980 se desarrolló la red Neocognitron (Fukushima, 1980). La red Neocognitron fue uno de los primeros modelos de aprendizaje profundo utilizados para el reconocimiento de caracteres. La red estaba compuesta por múltiples capas, cada una de las cuales procesaba información visual en diferentes niveles de abstracción.

A pesar de que la red Neocognitron fue un gran avance en el reconocimiento de caracteres, todavía tenía limitaciones. En particular, la red no podía reconocer caracteres escritos a mano que eran muy diferentes de los caracteres que se habían utilizado para entrenar la red.

A fines de la década de 1980, se presentó un enfoque importante para el reconocimiento de dígitos escritos a mano llamado “Sistema Neuronal de Reconocimiento de Dígitos” (LeCun et al., 1989). Este sistema utilizó una red neuronal de varias capas y fue entrenado utilizando el método de retropropagación del error. El modelo tuvo un rendimiento significativamente mejor que los enfoques anteriores y sentó las bases para el desarrollo de sistemas de reconocimiento de dígitos escritos a mano más sofisticados.

En la década de 1990 se desarrollaron otros modelos de aprendizaje profundo que superaron las limitaciones de los enfoques anteriores. LeCun et al. (1995) se menciona por primera vez el término de *red convolucional*.

Desde entonces, los algoritmos de reconocimiento de caracteres han seguido evolucionando y mejorando. Actualmente, los sistemas de reconocimiento de caracteres son capaces de reconocer caracteres escritos a mano con una precisión cercana al 100 %. Además del reconocimiento de caracteres, estas técnicas también se han utilizado para la detección de objetos en imágenes y videos, así como para la traducción automática.

2.2. Redes neuronales

McCulloch y Pitts (1943) estudiaron y propusieron un modelo del comportamiento de la neurona biológica. La neurona artificial que propusieron fue un sistema binario que consiste en que si la suma de entradas excitatorias supera un umbral de activación, y además no hay una entrada inhibitoria, la neurona se activa y emite una respuesta; en caso contrario, la neurona no se activa.

En 1949 se propone que estas redes podían aprender. Este hecho estaba relacionado con la conductividad de la sinapsis. Así, la repetida activación de una neurona por otra, a través de una sinapsis determinada, aumenta su conductividad y la hace más propensa a ser activada sucesivamente, induciendo a la formación de un circuito de neuronas estrechamente conectadas entre sí (Hebb, 1949).

Años más tarde, Rosenblatt (1958) propone un modelo de neurona llamado perceptrón basado en el modelo de McCulloch y Pitts. El mayor logro de Rosenblatt fue que pudo demostrar que, flexibilizando algunas de las reglas de McCulloch y Pitts (la inhibición absoluta, la contribución igual de todas las entradas, etc.), las neuronas artificiales podían aprender de los datos. Y lo que es más importante, ideó un algoritmo de aprendizaje supervisado para este modelo de neurona que permitía averiguar los pesos correctos directamente a partir de los datos de entrenamiento. La sencillez y eficacia de este algoritmo de aprendizaje para problemas linealmente separables son algunas de las razones clave por las que se hizo tan popular a finales de los años cincuenta y principios de los sesenta. Sin embargo, esta popularidad hizo que Rosenblatt exagerara la capacidad de aprendizaje de su perceptrón, dando lugar a expectativas poco realistas en la comunidad científica y/o también difundidas por los medios de comunicación.

En 1969, se publica un libro en el cual se expone la naturaleza lineal de los perceptrones y de sus limitadas capacidades (Minsky y Papert, 1969). A

raíz de este evento es que se inicia el denominado “invierno de la inteligencia artificial” de los 1980, donde cesó el interés de la comunidad por los modelos conexionistas.

La contribución más importante en la reemergencia del conexionismo en los años ochenta fue la técnica *backpropagation* desarrollada por Rumelhart, Hinton y Williams (1986). En realidad, esta técnica fue desarrollada inicialmente por Werbos (1974) y después redescubierta por varios grupos de investigadores (LeCun, 1985; Rumelhart, Hinton y Williams, 1986). Este algoritmo abrió las puertas al uso práctico de las redes neuronales en un sinfín de campos. La idea detrás del *backpropagation* es ajustar los pesos de una red neuronal para minimizar el error de predicción en un conjunto de datos de entrenamiento. Este error se calcula como la diferencia entre la salida real de la red y la salida deseada para una entrada dada. Para ajustar los pesos de la red, se utilizan las derivadas parciales del error con respecto a cada uno de los pesos, lo que permite actualizar los pesos en la dirección que minimiza el error. El entrenamiento de una red utilizando *backpropagation* se divide en dos fases: la propagación hacia adelante y la propagación hacia atrás. En la fase de propagación hacia adelante, se calcula la salida de la red para una entrada dada. La salida de la red se compara con la salida deseada para calcular el error de predicción. En la fase de propagación hacia atrás, se utiliza este error para calcular las derivadas parciales del error con respecto a cada uno de los pesos de la red. Este algoritmo ajusta los pesos en la dirección que minimiza el error de la red, multiplicando la derivada parcial del error por una tasa de aprendizaje y restando el resultado del peso correspondiente.

Las redes neuronales más “simples” entrenadas con *backpropagation*, son las denominadas redes multicapa alimentadas hacia delante (*feed forward*) o perceptrones multicapa *MLP*. En 1989, se demuestra teóricamente que una red de este tipo, con una capa oculta y el suficiente número de nodos, puede aproximar cualquier función continua con cualquier grado de precisión (Funahashi, 1989).

2.2.1. Redes densas

Como se detalló anteriormente, los perceptrones son modelos lineales incapaces de resolver problemas que no sean linealmente separables por un hiperplano. Una forma de solventar esta situación es encadenar un conjunto de perceptrones para crear redes neuronales densas (ver figura 2.1). La predicción \hat{y} de una red es una generalización directa de la predicción de un perceptrón. Primero se calculan las activaciones a_i^1 de los nodos de la capa oculta h_i^1 en función de las entradas x_i y los pesos de entrada w_i^1 . Luego, se calculan las activaciones a_i^2 de la unidad de salida h_i^2 dadas las activaciones de la capa anterior y los pesos w_i^2 .

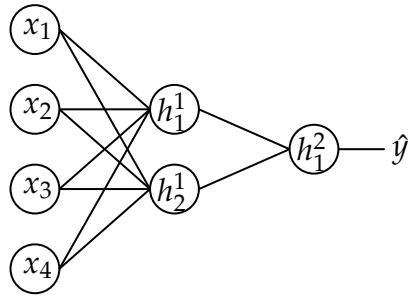


FIGURA 2.1: Red neuronal con una capa de entrada de cuatro características, una capa oculta de dos neuronas y una capa de salida con una neurona.

La única diferencia entre este cálculo y el del perceptrón es que las unidades ocultas calculan una función no lineal de sus entradas. Generalmente es llamada como *función de activación* o *función de enlace*. Formalmente, si $w_{i,d}$ son los pesos que conectan las entradas d a la unidad oculta i , entonces la activación de la unidad i se calcula como:

$$h_i = f(\mathbf{w}_i \cdot \mathbf{x} + b_i) \quad (2.1)$$

donde f es la función de activación, \mathbf{w}_i es el vector de pesos que alimentan el nodo i y b_i es el término de *bias*. Existen múltiples funciones de activación, las más comunes son:

- Tangente hiperbólica: $f(x) = \tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$
- Función sigmoidea: $f(x) = \sigma(x) = \frac{1}{1+exp(-x)}$
- ReLU: $f(x) = max(0, x)$
- Softmax: $f(x_i) = \sigma(x_i) = \frac{e^{x_i}}{\sum_{j=1}^K e^{x_j}}$ para $i = 1, 2, \dots, K$ donde K son la cantidad de neuronas de salida.

2.2.2. Redes convolucionales

Una de las principales limitaciones de las redes densas es su incapacidad para manejar datos que presentan una estructura espacial, como imágenes o audio. Esta limitación se debe principalmente al problema de la invarianza espacial, donde una misma entidad (por ejemplo, el dígito '6') puede tener diferentes ubicaciones en una imagen. Dado que las redes densas tratan cada entrada de manera *aislada*, ignorando las relaciones espaciales entre ellas, es posible que no detecten patrones o características importantes en los datos, lo que puede reducir su rendimiento.

Para solucionar este problema, surgió la idea de utilizar redes neuronales convolucionales (CNN). Estas redes se basan en utilizar capas de neuronas que comparten pesos y realizan una operación de convolución en los datos de entrada. Esto permite que la red tenga una mayor capacidad para detectar

patrones y características en los datos, ya que las neuronas de las capas de convolución están compartiendo información y pueden detectar patrones a diferentes escalas y en diferentes posiciones de los datos.

Matemáticamente, la operación de convolución se puede representar como:

$$(f * g)(x) = \int_{-\infty}^{\infty} f(t)g(x-t)dt \quad (2.2)$$

donde f y g son dos funciones y $*$ es el operador de convolución. Esta operación consiste en desplazar la función g invertida a través de la función f y multiplicar cada valor de f por el valor de g en esa posición. El resultado de la operación de convolución es una nueva función que refleja la combinación de los valores de f y g .

En la figura 2.2 se ilustra el proceso de cálculo de una convolución para escenarios discretos. Para una matriz I de tamaño 6×6 y un filtro K de tamaño 3×3 , la operación de convolución $*$ en una CNN aplica el filtro K deslizándolo sobre la matriz I para producir $I * K$.

$$\begin{pmatrix} 0 & 1 & 1 & 1 & 0 & 0 \\ 0 & 0 & 1 & 1 & 1 & 0 \\ 0 & 1 & -0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 1 & 0 & 0 \\ 0 & 1 & 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 & 0 \end{pmatrix} * \begin{pmatrix} 1 & 0 & 1 \\ 0 & 1 & 0 \\ 1 & 0 & 1 \end{pmatrix} = \begin{pmatrix} 1 & 5 & 2 & 3 \\ 3 & 2 & 4 & 2 \\ 1 & 4 & 2 & 1 \\ 3 & 2 & 1 & 1 \end{pmatrix}$$

I K $I * K$

FIGURA 2.2: Ejemplo de una convolución para una matriz I y un filtro o kernel K , produciendo la matriz $I * K$.

En una CNN, la matriz I representa la imagen y el filtro K es el conjunto de parámetros entrenables del modelo, análogo a las neuronas en una red densa. Aunque existen filtros estudiados para detectar ciertas características, como el filtro Sobel para detectar bordes, se permite que la red aprenda de forma autónoma K con el fin de detectar las características relevantes $I * K$ para la tarea en cuestión a través del entrenamiento. Esto permite que la red encuentre características sin el sesgo que se introduciría al utilizar únicamente filtros predefinidos.

Una de las principales ventajas de las CNN es que son capaces de procesar datos con una gran cantidad de dimensiones, como imágenes con altura, anchura y profundidad (canales de color). Esto se debe a que las capas de convolución son capaces de realizar operaciones de filtrado sobre los datos de entrada, permitiendo a la red aprender características específicas de los datos de manera eficiente. Además, las CNN tienen la capacidad de generalizar de manera efectiva, lo que significa que son capaces de realizar buenas predicciones en conjuntos de datos desconocidos.

Otra ventaja de las CNN es que cuentan con capas de *pooling* o también llamadas de sub muestreo. Su objetivo principal es reducir el tamaño espacial de la representación de características para disminuir la cantidad de parámetros y de operaciones necesarias en la red, lo que permite reducir el costo computacional y evitar el sobre ajuste. Además, al reducir el tamaño de la representación, se logra una cierta invarianza en las características aprendidas por la red, lo que significa que la posición exacta de las características dentro de la imagen ya no importa tanto. La operación de *pooling* en una CNN consiste en dividir la imagen de entrada en subregiones no superpuestas y aplicar una función a cada subregión. En general, existen tres tipos de funciones que se utilizan en *pooling*: *max pooling*, que toma el valor máximo de cada subregión; *average pooling*, que toma el valor promedio de cada subregión; y *min pooling*, que toma el valor mínimo de cada subregión. La figura 2.3 ilustra el cálculo de *max pooling* a la matriz $I * K$ del ejemplo anterior.

$$\left(\begin{array}{cc|cc} 1 & 5 & 2 & 3 \\ 3 & 2 & 4 & 2 \\ \hline 1 & 4 & 2 & 1 \\ 3 & 2 & 1 & 1 \end{array} \right) \xrightarrow{\text{maxpool}} \left(\begin{array}{c|c} 5 & 4 \\ \hline 4 & 2 \end{array} \right)$$

$I * K$ $\text{maxpool}(I * K)$

FIGURA 2.3: Maxpool 2×2 aplicado al ejemplo de la figura 2.2
 $I * K$.

Las redes neuronales convolucionales tienen una gran variedad de aplicaciones prácticas en diferentes campos, algunas de las cuales incluyen:

- Reconocimiento de imágenes: CNN se utilizan ampliamente en tareas de clasificación de imágenes, como el reconocimiento de objetos, el análisis de sentimientos en imágenes, la generación de descripciones automáticas para imágenes, entre otras (Krizhevsky, Sutskever e Hinton, 2017).
- Análisis de videos: CNN también se utilizan en tareas de análisis de videos, como el seguimiento de objetos, la detección de eventos, la generación de subtítulos automáticos para videos, entre otras (Simonyan y Zisserman, 2014).
- Procesamiento de lenguaje natural: CNN también se utilizan en tareas de procesamiento de lenguaje natural, como la clasificación de texto, la generación de texto, el análisis de sentimientos y la traducción automática (Bugnon et al., 2020).
- Medicina: CNN se utilizan en tareas de diagnóstico médico, como la detección de cáncer de mama, la detección de enfermedades cardíacas, la detección de problemas en imágenes médicas, entre otras (Wang et al., 2016).

2.2.3. Arquitecturas

Existen distintos tipos de arquitecturas de redes neuronales convolucionales debido a que cada una tiene diferentes fortalezas y debilidades en términos de capacidad de generalización, extracción de características y rendimiento (LeCun, Bengio e Hinton, 2015). Algunos factores que pueden influir en la elección de una arquitectura en particular incluyen (He et al., 2016):

- Tamaño de los datos de entrada: para procesar grandes conjuntos de datos, es posible que se necesite una red con una mayor capacidad de procesamiento y una mayor cantidad de parámetros.
- Nivel de detalle de las características: algunas arquitecturas pueden ser más eficientes para detectar características a diferentes escalas y en diferentes posiciones, mientras que otras pueden tener una mayor capacidad para detectar patrones complejos.
- Nivel de generalización: algunas arquitecturas pueden ser más capaces de generalizar a datos nuevos y menos vistos durante el entrenamiento, mientras que otras pueden ser más propensas a sobre ajuste.
- Requerimientos de tiempo y recursos: algunas arquitecturas pueden requerir más tiempo y recursos para entrenar y evaluar, lo que puede ser un factor importante a considerar dependiendo de los objetivos del proyecto.

Una arquitectura simple de CNN para la clasificación de imágenes es la ilustrada en la figura 2.4: una subred convolucional \mathcal{G} que extrae información y genera características \mathbf{z} a partir de la entrada \mathbf{x} ; y una subred densa \mathcal{C} que se encarga de clasificar las características aprendidas \mathbf{z} en las etiquetas del problema $\hat{\mathbf{y}}$.

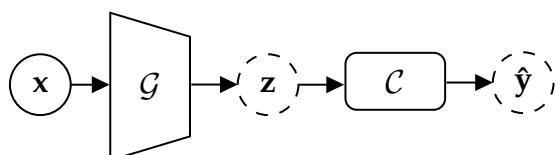


FIGURA 2.4: Arquitectura de una red convolucional simple. Las entradas \mathbf{x} son procesadas por una red convolucional \mathcal{G} que generan características \mathbf{z} para luego ser clasificadas por una red densa \mathcal{C} en $\hat{\mathbf{y}}$.

Tal es el caso de la red LeNet, que fue propuesta por LeCun et al. (1998). Esta red consta de dos capas de convolución seguidas por dos capas densas y una capa de salida, y fue utilizada con éxito para el reconocimiento de números escritos a mano en el conjunto de datos MNIST.

Por otro lado, una arquitectura de red neuronal convolucional más compleja es la red ResNet (abreviación de Residual Network), propuesta por He et al. (2016). Estas redes están diseñadas para resolver el problema de la propagación del gradiente en las redes neuronales profundas, lo que permite entrenar modelos con una gran cantidad de capas.

LeNet

LeNet es una de las primeras arquitecturas de redes neuronales de aprendizaje profundo desarrolladas para tareas de reconocimiento de caracteres escritos a mano. Aunque la arquitectura original de LeNet es bastante antigua, su diseño sigue siendo relevante hoy en día y se utiliza como una arquitectura básica para tareas similares.

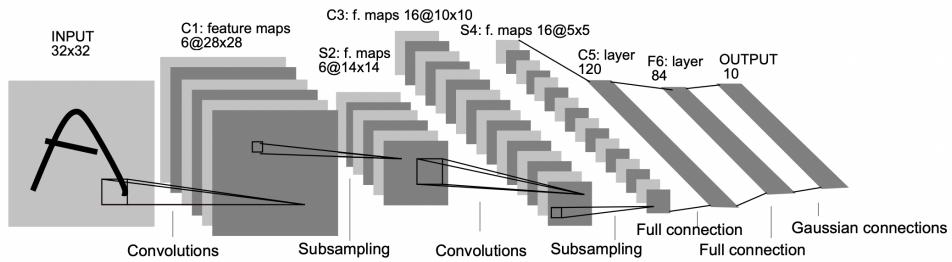


FIGURA 2.5: Arquitectura de una LeNet5. Imagen tomada de LeCun et al. (1998).

El desarrollo de la LeNet implicó la aparición de las CNN y sus componentes básicos. No obstante, no fue popular en su momento debido a la falta del hardware necesario para entrenarlas y otros algoritmos como las máquinas de vectores de soporte (SVM por sus siglas en inglés) que podían obtener resultados similares o superadores (LeCun et al., 1998; DeCoste y Schölkopf, 2002; Lauer, Suen y Bloch, 2007).

En 2012, Alex Krizhevsky ganó la competencia de ImageNet con su arquitectura AlexNet (Krizhevsky, Sutskever e Hinton, 2017), basada en la LeNet pero con modificaciones. La principal diferencia entre ambas es la complejidad y profundidad de la arquitectura: AlexNet con ocho capas y más de 60 millones de parámetros entrenables, mientras que LeNet tiene cinco capas y menos de un millón de parámetros. Además, AlexNet utiliza filtros convolucionales más grandes (11×11 y 5×5) que permiten capturar características de imagen más grandes y complejas, y técnicas de regularización más avanzadas, como el *dropout*, para prevenir el sobre ajuste. En contraste, LeNet utiliza filtros más pequeños (5×5 y 3×3) y técnicas de regularización más simples como la regularización L2.

Desde el éxito de AlexNet, las CNN se han convertido en la mejor opción para aplicaciones de visión computacional y se han creado muchos tipos diferentes de CNN, como las redes R-CNN utilizada para detección y segmentación de objetos (Girshick et al., 2014). En la actualidad los modelos CNN son bastante diferentes de LeNet original, pero todos se desarrollan sobre la base generada por esta.

ResNet

La idea principal detrás de las redes ResNet es la utilización de *bloques residuales* en lugar de las capas tradicionales de la red neuronal. Un bloque residual se compone de varias capas de una red neuronal tradicional, pero con

una conexión residual que permite que la información de entrada se sume directamente a la salida de las capas internas. Esto permite que la información se propague de manera más eficiente a través de las capas profundas de la red, lo que ayuda a reducir el problema del desvanecimiento de gradientes en la retropropagación del error.

Además, las redes ResNet también utilizan una técnica llamada *bottleneck* que reduce el número de canales de salida en las capas internas del bloque residual, lo que ayuda a reducir el número de parámetros y mejorar la eficiencia del modelo obligando a la red a aprender características más relevantes.

Las redes neuronales ResNet se han desarrollado en diferentes arquitecturas, cada una de las cuales tiene su propio conjunto de características y aplicaciones. Las mismas son:

- ResNet18 y ResNet34 (He et al., 2016): son arquitecturas de ResNet con un número moderado de capas (18 y 34 respectivamente) que se utilizan comúnmente en tareas de clasificación de imágenes y reconocimiento de objetos.
- ResNet50, ResNet101 y ResNet152 (He et al., 2016): son arquitecturas de ResNet con un mayor número de capas (50, 101 y 152 respectivamente) que se utilizan comúnmente en tareas de detección de objetos y segmentación de imágenes. Estas arquitecturas tienen una mayor capacidad representativa y son más precisas en las tareas de aprendizaje profundo complejas, pero requieren más tiempo de entrenamiento y recursos.
- ResNet-S y ResNet-M (Sandler et al., 2018): son arquitecturas de ResNet que se utilizan en dispositivos móviles y sistemas de baja potencia. Estas arquitecturas son más ligeras en términos de parámetros y requisitos de cálculo que las arquitecturas anteriores.
- ResNeXt (Xie et al., 2017): es una variante de ResNet que utiliza una técnica llamada *agrupación cardinal* para mejorar la capacidad representativa de la red. Esta técnica utiliza varios grupos de canales en lugar de uno solo para mejorar la capacidad representativa del modelo y lograr mejores resultados en tareas de clasificación y reconocimiento.

2.3. Aprendizaje por transferencia

El aprendizaje por transferencia es una técnica que consiste en utilizar lo que se ha aprendido en una tarea para mejorar el rendimiento en otra tarea relacionada (Thrun y Pratt, 1998). Esta técnica se aplica comúnmente en el contexto de redes neuronales, especialmente en tareas de imágenes, y se basa en la idea de que algunos conocimientos adquiridos en una tarea pueden ser reutilizados en otra tarea, lo que permite que la red aprenda de manera más eficiente y con menos datos. Ha ganado popularidad en los últimos años debido a la creciente cantidad de datos disponibles y a la necesidad de entrenar modelos más complejos y de mayor rendimiento.

En el contexto de las redes neuronales, el aprendizaje por transferencia se puede llevar a cabo de varias maneras, como el *pre-entrenamiento* y el *fine-tuning*. El pre-entrenamiento es una técnica de aprendizaje por transferencia en la que se entrena una red en una tarea y luego se utiliza como punto de partida para entrenar otra red en una tarea diferente (Erhan et al., 2010). Esto permite que la red aprenda de manera más rápida y con menos datos, ya que ya ha adquirido algunos conocimientos en la primera tarea. El pre-entrenamiento se puede llevar a cabo de varias maneras, como por ejemplo entrenando una red en un conjunto de datos de gran tamaño y luego utilizándola como inicialización para una tarea específica de menor tamaño. Esto se ha utilizado con éxito en varias tareas de aprendizaje automático, como la clasificación de imágenes (Chen et al., 2021) y el procesamiento del lenguaje natural (Liu y Lapata, 2019). También se ha utilizado con éxito en el contexto de redes neuronales profundas, donde ha demostrado ser una técnica efectiva para mejorar el rendimiento y la capacidad de generalización de las redes (Girshick et al., 2014).

Por otro lado, el fine-tuning es una técnica en la que se utilizan las capas de una red pre-entrenada en una tarea como capas fijas en otra red que se entrena en una tarea diferente (Yosinski et al., 2014), sin modificar los pesos de la red pre-entrenada. Esto permite que la red aprenda las características específicas de la nueva tarea y con menos datos (Howard y Ruder, 2018).

2.4. Adaptación de dominio

El *pre-entrenamiento* y el *fine-tuning* han mejorado considerablemente el estado del arte para diversos problemas y aplicaciones del machine learning, incluso las redes profundas pre-entrenadas pueden adaptarse fácilmente a tareas donde se cuenta con una pequeña cantidad de datos etiquetados. Sin embargo, en muchos escenarios prácticos, no hay datos de entrenamiento etiquetados y, por lo tanto, existe la necesidad de transferir el aprendizaje de una red profunda desde un dominio de origen en el que se dispone de datos de entrenamiento etiquetados a un dominio de destino en el que solo existen datos sin etiquetar (Glorot, Bordes y Bengio, 2011). En esta situación, los modelos profundos siguen sufriendo degradaciones de rendimiento debido al cambio de distribución (Quinonero-Candela et al., 2008). Por lo tanto, se propone la *adaptación de dominio* para reducir el cambio de distribución entre los dominios de entrenamiento y de prueba (Jiang et al., 2022).

La capacidad de adaptación de dominio es una medida que se utiliza para evaluar el rendimiento de un modelo de aprendizaje automático en un dominio de prueba diferente al dominio en el que se entrenó. Uno de los factores clave que influyen en la capacidad de adaptación de dominio es la calidad de los espacios latentes que genera el modelo durante la etapa de entrenamiento.

El espacio latente en el contexto de las redes convolucionales se refiere a una representación de los datos de entrada que se ha aprendido durante el entrenamiento del modelo. Durante dicho proceso, la red aprende a extraer

características relevantes de las imágenes de entrada a través de la etapa convolucional. El espacio latente \mathbf{z} se genera después de la etapa convolucional y antes de la etapa densa de la red. En este espacio latente, cada dimensión representa una característica específica de la imagen de entrada. Por ejemplo, en el caso de una red convolucional entrenada para clasificar imágenes de gatos y perros, una dimensión podría representar la forma de las orejas y otra dimensión podría representar el color de la nariz.

Para evaluar la capacidad de adaptación de dominio de un modelo, se pueden comparar las distribuciones de los espacios latentes generados para diferentes conjuntos de datos. En general, se espera que los espacios latentes generados para diferentes conjuntos de datos sean similares, ya que esto indica que el modelo es capaz de generalizar.

Si los espacios latentes son iguales o similares para diferentes conjuntos de datos, la etapa densa de la red que se encarga de la clasificación puede realizar predicciones precisas para el dominio de destino. Por otro lado, si los espacios latentes son muy diferentes para diferentes conjuntos de datos, esto puede indicar que el modelo no es capaz de adaptarse a nuevos conjuntos de datos y, por lo tanto, su capacidad de generalización es limitada.

Se han propuesto muchos métodos para la adaptación de dominios, ya sea ponderando o seleccionando muestras del dominio de origen (Sugiyama et al., 2007) o buscando una transformación de la distribución de origen a la distribución de destino (Gong, Grauman y Sha, 2013). Esta tesis analizará algunos de los métodos más comunes del último caso debido a que es donde existe mayor investigación y algoritmos.

2.4.1. Red neuronal adversaria de dominio

Un gran hito al momento de modelar distribuciones es la Red Adversaria Generativa *GAN* (Goodfellow et al., 2020). Estas son un tipo de arquitectura de redes neuronales compuesta por dos componentes principales: el generador \mathcal{G} y el discriminador \mathcal{D} . Estas redes se entranan de forma adversaria, lo que significa que se enfrentan y aprenden de manera competitiva. El generador tiene la tarea de crear datos sintéticos $\hat{\mathbf{x}}$, como imágenes o texto, que se asemejen a los datos reales del conjunto de entrenamiento \mathbf{x} a partir de un espacio latente \mathbf{z} que suele ser aleatorio. Por otro lado, el discriminador actúa como un clasificador que intenta distinguir entre las muestras generadas por el generador y las muestras reales del conjunto de entrenamiento. El objetivo principal es entrenar al generador para que sea capaz de engañar al discriminador, generando muestras que sean indistinguibles de las reales. Para lograr esto, el generador y el discriminador se entranan de manera alternada. Durante el entrenamiento, el generador intenta mejorar su capacidad para generar muestras más realistas, mientras que el discriminador trata de mejorar su capacidad para distinguir entre las muestras generadas y las reales. Este proceso de entrenamiento adversario continúa hasta que se alcanza un punto de equilibrio en el que el generador es capaz de generar muestras que el discriminador no puede distinguir de las reales. Una vez que se ha alcanzado

este punto, el generador puede utilizarse para generar nuevas muestras sintéticas que sean similares a los datos reales. La figura 2.6 muestra el esquema de las GAN descrito anteriormente.

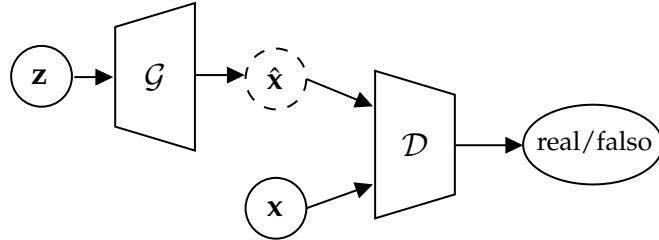


FIGURA 2.6: Esquema de una GAN. z es el espacio latente con el cual la red generadora \mathcal{G} produce datos sintéticos \hat{x} . Luego, la red discriminadora \mathcal{D} intenta distinguir entre los datos sintéticos \hat{x} y los datos reales x . Con el tiempo, \mathcal{G} irá generando datos similares a los reales y \mathcal{D} no podrá distinguir los unos de los otros.

Inspirada en estas arquitecturas GAN, la Red Neuronal Adversaria de Dominio *DANN* (Ganin et al., 2016) contiene de tres componentes clave: la generadora de características \mathcal{G} , la discriminadora de dominios \mathcal{D} y la red clasificadora \mathcal{C} como se ilustra en la figura 2.7. En primer lugar, la generadora de características \mathcal{G} se entrena con el objetivo de confundir a la discriminadora \mathcal{D} y al mismo tiempo ayudar a la red clasificadora \mathcal{C} . La idea principal es que \mathcal{G} aprenda a generar características que sean similares en ambos dominios, de manera que la discriminadora \mathcal{D} se equivoque al distinguir entre las características de origen y destino. Esta estrategia de engañar a \mathcal{D} ayuda a \mathcal{C} a clasificar correctamente las características entre ambos dominios. Por otro lado, la discriminadora de dominios \mathcal{D} es entrenada para diferenciar entre las características de origen y las de destino. Su función es detectar las diferencias inherentes a cada uno de ellos. Al entrenar a \mathcal{D} en la discriminación de dominios, se impulsa a \mathcal{G} a generar características que sean indistinguibles para \mathcal{D} , fomentando así la adaptación de dominio.




FIGURA 2.7: Esquema de las *DANN*. Los supra índices s y t indican si los datos son del origen o destino respectivamente. Los círculos con líneas rayadas son salidas de los modelos mientras que los círculos de líneas sólidas son datos conocidos.

El objetivo de *DANN* consiste en minimizar función de pérdida que depende de \mathcal{L}_C y \mathcal{L}_{adv} . \mathcal{L}_C mide el error que posee la red en la clasificación de

los datos de origen y viene dada por el *cross-entropy* \mathcal{L}_{CE} aplicado a la salida de la red \mathcal{C} . El objetivo de \mathcal{D} será la descrita en la ecuación 2.3:

$$\begin{aligned} \min_{\mathcal{C}} \mathcal{L}_{\mathcal{C}}(\mathbf{x}^s, \mathbf{y}^s) &= \mathcal{L}_{CE}(C(\mathcal{G}(\mathbf{x}^s)), \mathbf{y}^s) \\ &= \mathcal{L}_{CE}(C(\mathbf{z}^s), \mathbf{y}^s) \\ &= \mathcal{L}_{CE}(\hat{\mathbf{y}}^s, \mathbf{y}^s) \end{aligned} \quad (2.3)$$

La función de pérdida de \mathcal{D} viene dada por la ecuación 2.4, donde $\mathbb{E}_{\mathbf{x}^s \sim \hat{\mathcal{S}}}$ y $\mathbb{E}_{\mathbf{x}^t \sim \hat{\mathcal{T}}}$ representan la proporción esperada de datos de origen $\hat{\mathcal{S}}$ y destino $\hat{\mathcal{T}}$ respectivamente.

$$\begin{aligned} \max_{\mathcal{D}} \mathcal{L}_{adv}(\mathbf{x}^s, \mathbf{x}^t) &= \mathbb{E}_{\mathbf{x}^s \sim \hat{\mathcal{S}}} \log[\mathcal{D}(\mathcal{G}(\mathbf{x}^s))] + \mathbb{E}_{\mathbf{x}^t \sim \hat{\mathcal{T}}} \log[1 - \mathcal{D}(\mathcal{G}(\mathbf{x}^t))] \\ &= \mathbb{E}_{\mathbf{x}^s \sim \hat{\mathcal{S}}} \log[\mathcal{D}(\mathbf{z}^s)] + \mathbb{E}_{\mathbf{x}^t \sim \hat{\mathcal{T}}} \log[1 - \mathcal{D}(\mathbf{z}^t)] \\ &= \mathbb{E}_{\mathbf{x}^s \sim \hat{\mathcal{S}}} \log[\mathbf{d}^s] + \mathbb{E}_{\mathbf{x}^t \sim \hat{\mathcal{T}}} \log[1 - \mathbf{d}^t] \end{aligned} \quad (2.4)$$

Por lo tanto, el objetivo de un modelo *DANN* viene dado por la ecuación 2.5. Donde λ es un hiperparámetro a optimizar que regula el trade-off entre la clasificación y la discriminación adversaria. La minimización de $\mathcal{L}_{\mathcal{C}}$ dará lugar a representaciones discriminables, mientras que la disminución de \mathcal{L}_{adv} dará lugar a representaciones transferibles.

$$\min_{\mathcal{G}, \mathcal{C}} \mathcal{L}_{\mathcal{C}}(\mathbf{x}^s, \mathbf{y}^s) + \lambda \mathcal{L}_{adv}(\mathbf{x}^s, \mathbf{x}^t) \quad (2.5)$$

2.4.2. Adaptación de dominio adversaria discriminativa

Las redes Adaptación de Dominio Adversaria Discriminativa *ADDA* (Tzeng et al., 2017) surgen a partir de las *DANN* como propuesta para mitigar el desvanecimiento de gradiente, un problema importante en el entrenamiento de GAN. Por ejemplo, cuando el espacio latente de destino generado \mathbf{z}^t es extremadamente distingible del de origen tal que $\mathcal{D}(\mathbf{z}^t) = 0$, el gradiente es pequeño y viceversa. Esto provoca que la optimización de \mathcal{G} sea extremadamente difícil.

Las redes *ADDA* separan la optimización de \mathcal{G} y de \mathcal{D} en dos objetivos independientes como se muestra en la figura 2.8. El primero es el pre-entrenamiento de \mathcal{G}_s y \mathcal{C} en los datos de origen y el otro la adaptación adversaria de una \mathcal{G}_t utilizando a \mathcal{G}_s pre-entrenada y \mathcal{D} .

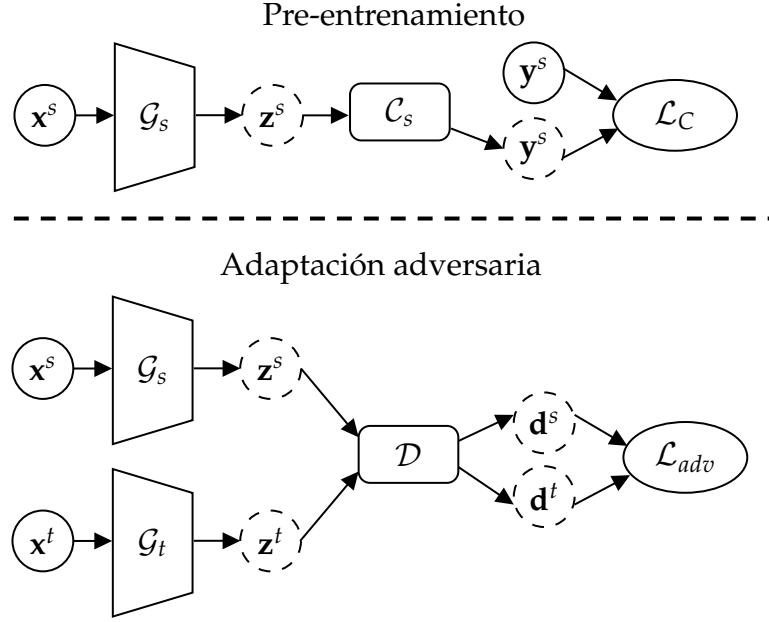


FIGURA 2.8: Esquema de las ADDA. Los supra indices s y t indican si los datos son del origen o destino respectivamente. Los círculos con líneas rayadas son salidas de los modelos mientras que los círculos de líneas sólidas son datos conocidos. La primera fase consta de un pre-entrenamiento con una red generadora \mathcal{G}_s con los datos origen y la segunda fase de adaptación consta de otra red generadora \mathcal{G}_t que debe aprender a generar el mismo espacio latente que \mathcal{G}_s con los datos de destino para confundir a \mathcal{D} .

No obstante del cambio, los objetivos de ADDA son similares a los de las DANN a excepción de \mathcal{G}_t . La ecuación 2.6 contiene \mathcal{L}_C que es análoga a 2.3.

$$\min_{\mathcal{G}_s, \mathcal{C}} \mathcal{L}_C(\mathbf{x}^s, \mathbf{y}^s) = \mathcal{L}_{CE}(\mathcal{C}_s(\mathcal{G}_s(\mathbf{x}^s)), \mathbf{y}^s) \quad (2.6)$$

La función de costo de la discriminación adversaria \mathcal{L}_{adv} detallada a continuación es análoga a la ecuación 2.4 de DANN.

$$\max_{\mathcal{D}} \mathcal{L}_{adv}(\mathbf{x}^s, \mathbf{x}^t) = \mathbb{E}_{\mathbf{x}^s \sim \hat{\mathcal{S}}} \log[\mathcal{D}(\mathcal{G}_s(\mathbf{x}^s))] + \mathbb{E}_{\mathbf{x}^t \sim \hat{\mathcal{T}}} \log[1 - \mathcal{D}(\mathcal{G}_t(\mathbf{x}^t))] \quad (2.7)$$

Finalmente, la ecuación 2.8 contiene el objetivo a optimizar de un modelo ADDA, que asigna gradientes pequeños a registros de destino que sean similares a los de origen y gradientes más grandes para los otros registros de destino.

$$\min_{\mathcal{G}_t} -\mathbb{E}_{\mathbf{x}^t \sim \hat{\mathcal{T}}} \log[\mathcal{D}(\mathcal{G}_t(\mathbf{x}^t))] \quad (2.8)$$

2.4.3. Penalización espectral en lotes

Aunque los métodos de adaptación de dominio adversarios mejoran la *transferibilidad* de las características aprendidas; es decir, la capacidad de que las representaciones puedan superar las discrepancias entre los dominios, lo hacen a costa de la *discriminabilidad*; es decir, la facilidad de separar categorías sobre las representaciones de ambos dominios (Chen et al., 2019). Al aplicar descomposición en valores singulares (*SVD* en inglés) para analizar las propiedades espectrales de las representaciones aprendidas en batches, se confirma que los autovectores con valores singulares más altos dominan la *transferibilidad* mientras que los autovectores con valores singulares más pequeños se encuentran penalizados, lo que provoca una *discriminabilidad* deficiente. La Penalización Espectral en Lotes *BSP* (Chen et al., 2019) penaliza el mayor valor singular para que los demás autovectores puedan mejorar la *discriminabilidad*. \mathcal{L}_{BSP} es propuesto como un término de regularización sobre los k mayores valores singulares:

$$\mathcal{L}_{BSP}(\mathbf{z}) = \sum_{i=0}^k (\sigma_{s,i}^2 + \sigma_{t,i}^2), \quad (2.9)$$

donde $\sigma_{s,i}$ y $\sigma_{t,i}$ corresponden al i -ésimo mayor valor singular de Σ_s y Σ_t respectivamente del análisis espectral $\mathbf{z} = \mathbf{U}\Sigma\mathbf{V}^\top$. En la presente tesis se utilizará el valor por defecto propuesto por Chen et al. de $k = 1$.

BSP puede integrarse a cualquiera de los esquemas mencionados anteriormente, por ejemplo a una *DANN* como se muestra en la figura 2.9.




FIGURA 2.9: Esquema de un modelo *DANN+BSP*.

Por lo tanto, un modelo *DANN+BSP* presenta como objetivos:

$$\min_{\mathcal{G}, \mathcal{C}} \mathcal{L}_C(x^s, y^s) + \lambda \mathcal{L}_{adv}(x^s, x^t) + \beta \mathcal{L}_{BSP}(\mathcal{G}(\mathbf{x})) \quad (2.10)$$

$$\max_{\mathcal{D}} \mathcal{L}_{adv}(x^s, x^t), \quad (2.11)$$

donde β es el parámetro que regula el trade-off de \mathcal{L}_{BSP} .

2.4.4. Discrepancia de disparidad de margen

Otra manera de pensar en la adaptación de dominio es a través de la Discrepancia de Disparidad de Margen *MDD* (Zhang et al., 2019), esquematizado en la Figura 2.10. La idea general es que *MDD* incorpora un clasificador adversario \mathcal{C}' a \mathcal{C} , de manera que logre predecir correctamente los datos del dominio de origen, mientras que haga predicciones distintas a \mathcal{C} en los datos del dominio destino. Mediante la maximización de la discrepancia entre \mathcal{C}' y \mathcal{C} en el dominio destino, *MDD* impulsa al generador \mathcal{G} a generar características \mathbf{z} cerca de la frontera de decisión con el fin de evitar estas situaciones.

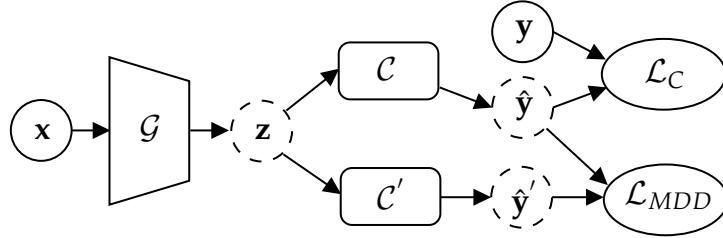


FIGURA 2.10: Esquema de *MDD*. Los círculos con líneas rayadas son salidas de los modelos mientras que los círculos de líneas sólidas son datos conocidos. *MDD* introduce un clasificador clasificador adversario \mathcal{C}' para maximizar la discrepancia y entrena el generador de características \mathcal{G} para minimizar el error de origen como también la discrepancia.

\mathcal{L}_C continúa siendo la función *cross-entropy* \mathcal{L}_{CE} aplicado a la salida de la red \mathcal{C} :

$$\min_{\mathcal{C}} \mathcal{L}_C(\mathbf{x}^s, \mathbf{y}^s) = \mathcal{L}_{CE}(C(\mathcal{G}(\mathbf{x}^s)), \mathbf{y}^s) \quad (2.12)$$

Por otro lado, \mathcal{L}_{MDD} contiene un *margen* ρ que se obtiene introduciendo el parámetro $\gamma \triangleq \exp \rho$ en la ecuación 2.13.

$$\begin{aligned} \max_{\mathcal{C}'} \mathcal{L}_{MDD}(\mathbf{x}^s, \mathbf{x}^t) = & \gamma \mathbb{E}_{\mathbf{x}^s \sim \hat{\mathcal{S}}} \log[\sigma(\mathcal{C}'(\mathcal{G}(\mathbf{x}^s)))] + \\ & \mathbb{E}_{\mathbf{x}^t \sim \hat{\mathcal{T}}} \log[1 - \sigma(\mathcal{C}'(\mathcal{G}(\mathbf{x}^t)))], \end{aligned} \quad (2.13)$$

donde σ es la función *softmax*. Por lo tanto, el objetivo de optimización viene dado por la ecuación 2.14, donde λ es el trade-off entre la clasificación y la discriminación adversaria.

$$\min_{\mathcal{G}, \mathcal{C}} \mathcal{L}_C(\mathbf{x}^s, \mathbf{x}^t) + \lambda \mathcal{L}_{MDD}(\mathbf{x}^s, \mathbf{x}^t) \quad (2.14)$$

2.4.5. Normalización de características adaptativa

El mayor problema que surge de la adaptación de dominio es la degradación del modelo en cuanto a la tasa de acierto en la clasificación (Yosinski et al., 2014). Las divergencias estadísticas existentes pueden no representar con precisión el cambio de dominio y subsanar tales discrepancias puede no garantizar la transferencia entre dominios. Tales discrepancias se ejemplifican en la figura 2.11 donde las características de origen son aquellas alineadas en distintas rectas, mientras que las de destino son aquellas que forman la nube de puntos del centro.




FIGURA 2.11: Representación t-SNE de dos dimensiones de las características aprendidas para el origen y destino utilizando un modelo entrenado en muestras del origen para el conjunto de datos VisDA (Peng et al., 2017). Imagen tomada de Xu et al. (2019).

Esto sugiere que las normas excesivamente pequeñas de las características de destino con respecto a las de origen explican el deterioro en la clasificación. No obstante, pueden plantearse dos hipótesis:

- Normas de las características desalineadas: el desplazamiento entre los dominios de origen y destino se explica en la desalineación de los valores esperados de las normas de sus características. La coincidencia de las normas de ambos dominios a un escalar arbitrariamente elegido supondrá una mejora en la transferencia.
- Norma de las características más pequeña: el desplazamiento entre los dominios se explica debido a las características menos informativas con normas más pequeñas del dominio de destino. Adaptar las características de destino a regiones alejadas de las normas pequeñas supondrá una mejora en la transferencia.

Xu et al. (2019) propone un método llamado Normalización de Características Adaptativa AFN, ilustrado en la figura 2.12, que consiste en normalizar las normas de las características aprendidas por la red \mathcal{G} mediante n bloques \mathcal{N} (compuestos por FC-BN-ReLU-Dropout) y mediante \mathcal{L}_{AFN} .

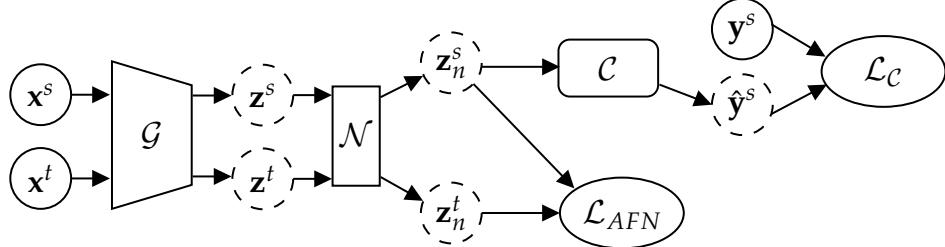


FIGURA 2.12: Esquema de AFN. Los supra indices s y t indican si los datos son del origen o destino respectivamente. Los círculos con líneas rayadas son salidas de los modelos mientras que los círculos de líneas sólidas son datos conocidos. El modelo *backbone* \mathcal{G} produce características \mathbf{z} que luego son aplicadas por bloques \mathcal{N} (FC-BN-ReLU-Dropout) produciendo características normalizadas \mathbf{z}_n . La red clasificadora \mathcal{C} toma las características \mathbf{z}_n^s , predice $\hat{\mathbf{y}}^s$ y se calcula $\mathcal{L}_{\mathcal{C}}$. Finalmente, \mathcal{L}_{AFN} se calcula utilizando \mathbf{z}_n .

En su variante iterativa, \mathcal{L}_{AFN} se define como:

$$\begin{aligned} \min_{\mathcal{G}} \mathcal{L}_{AFN}(\mathbf{x}^s, \mathbf{x}^t) = & \mathbb{E}_{\mathbf{x}^s \sim \mathcal{S}} \mathbb{E}[(\|\mathcal{N}(\mathcal{G}(\mathbf{x}^s))\| - \Delta_r)^2] \\ & + \mathbb{E}_{\mathbf{x}^t \sim \mathcal{T}} \mathbb{E}[(\|\mathcal{N}(\mathcal{G}(\mathbf{x}^t))\| - \Delta_r)^2], \end{aligned} \quad (2.15)$$

donde Δ_r corresponde al escalar que controla la amplitud de la norma. Los autores afirman que puede agregarse un término a la ecuación 2.15 respecto a la entropía \mathcal{H} de la función *softmax* σ para facilitar la discriminabilidad mediante un factor β :

$$\begin{aligned} \min_{\mathcal{G}} \mathcal{L}_{AFN}(\mathbf{x}^s, \mathbf{x}^t) = & \mathbb{E}_{\mathbf{x}^s \sim \mathcal{S}} \mathbb{E}[(\|\mathcal{N}(\mathcal{G}(\mathbf{x}^s))\| - \Delta_r)^2] \\ & + \mathbb{E}_{\mathbf{x}^t \sim \mathcal{T}} \mathbb{E}[(\|\mathcal{N}(\mathcal{G}(\mathbf{x}^t))\| - \Delta_r)^2] \\ & + \beta \mathcal{H}(\sigma(\mathcal{N}(\mathcal{G}(\mathbf{x}^s)))) \end{aligned} \quad (2.16)$$

Por lo tanto, el objetivo de optimización viene dado por la ecuación 2.17, donde λ es el trade-off entre la clasificación y normalización de normas.

$$\min_{\mathcal{G}, \mathcal{C}} \mathcal{L}_{\mathcal{C}}(\mathbf{x}^s, \mathbf{x}^t) + \lambda \mathcal{L}_{AFN}(\mathbf{x}^s, \mathbf{x}^t) \quad (2.17)$$

Capítulo 3

Metodología

En este capítulo se detallarán los procesos abordados para la extracción y clasificación de los dígitos escritos en los telegramas de las elecciones. Primero se describirá el proceso de obtención, limpieza y transformación de los datos a fin de obtener un conjunto de datos con el cual entrenar. Luego, se describirán los procesos a ser llevados a cabo para el diseño experimental de los modelos.

3.1. Descripción de los datos

Se descargaron los 8188 telegramas desde la página oficial del estado argentino en formato TIFF. Los mismos presentan un formato estándar en forma de grilla, en la que se encuentran los partidos políticos y los votos obtenidos para diputados y senadores en cada renglón. En la página también se puede descargar un archivo en formato CSV donde se encuentra el identificador de cada telegrama y los valores digitalizados oficialmente.

3.2. Extracción de dígitos de los telegramas

Durante las elecciones en Santa Fe, los telegramas de los votos presentaron un formato tabular en el que cada fila representaba a un partido político y los votos obtenidos se encontraban divididos por senadores y diputados. Para poder utilizar estos datos y entrenar modelos de aprendizaje automático, fue necesario llevar a cabo un proceso de extracción, transformación y carga (ETL) de los mismos.

Este proceso de ETL implicó la ejecución de múltiples pasos para extraer la información relevante de los telegramas y transformarla en un formato adecuado para su uso en modelos de aprendizaje automático. En primer lugar, se utilizó la librería OpenCV (Bradski, 2000) para manipular las imágenes de los telegramas y poder llevar a cabo el proceso de ETL.

A continuación, se realizó la extracción de la información tabular de los telegramas, identificando las filas correspondientes a cada partido político y los votos obtenidos por senadores y diputados. Este proceso también incluyó la limpieza y validación de los datos para asegurar su calidad y confiabilidad.

Posteriormente, se transformaron los datos extraídos en un formato adecuado para su uso en modelos de aprendizaje automático. Esto implicó la

normalización de los datos, la codificación de variables categóricas y la creación de variables adicionales para mejorar la calidad de los datos. Finalmente, se cargó el conjunto de datos procesados en un conjunto de datos que fue utilizado para entrenar los modelos.

3.2.1. Alineación de los telegramas

Cuando se escanean telegramas a mano, es común que estos no estén perfectamente alineados y presenten una ligera inclinación en su posición. Por lo tanto, el primer paso en el procesamiento de los telegramas es alinearlos para facilitar su lectura y análisis. Para lograr esto, se emplea un algoritmo que busca el rectángulo de mayor área en la imagen del telegrama. Este rectángulo representa la región que abarca todo el contenido del telegrama y se utiliza para calcular el ángulo de rotación necesario para alinear la imagen.

Una vez que se ha determinado el ángulo de rotación, se aplica una transformación geométrica a la imagen completa para alinearla verticalmente. La misma se realiza calculando la siguiente matriz:

$$\begin{bmatrix} \gamma & \beta & (1 - \gamma) \cdot x - \beta \cdot y \\ -\beta & \gamma & \beta \cdot x - (1 - \gamma) \cdot y \end{bmatrix} \quad (3.1)$$

donde α es el ángulo de rotación de la imagen, (x, y) es el centro de la imagen, $\gamma = \cos \alpha$ y $\beta = \sin \alpha$. La figura 3.1 muestra un ejemplo del resultado que se obtiene al alinear los telegramas de esta manera.

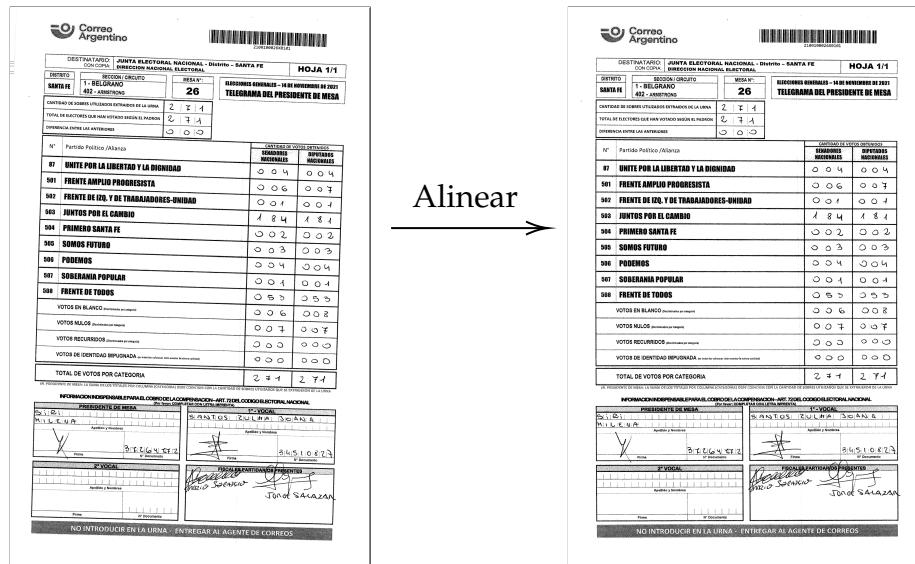


FIGURA 3.1: Proceso de alineación de un telegrama mediante el uso de OpenCV.

3.2.2. Extracción de la grilla de votos

El siguiente paso consiste en extraer la grilla de votos para trabajar con ella de manera aislada. Para lograrlo, se aplicó el algoritmo de detección de

contornos propuesto por Suzuki et al. (1985), el cual permite identificar y seleccionar los contornos presentes en la imagen, correspondientes a los bordes que delimitan los objetos en ella. Mediante la selección del contorno de mayor área, se obtiene la grilla de votos como un objeto independiente. Posteriormente, se procede a extraer la grilla de votos y trabajar con ella de manera separada del resto de la imagen. Esto simplifica el procesamiento de los datos y facilita la extracción y análisis de los votos presentes en la grilla. La figura 3.2 muestra la grilla extraída mediante este proceso.

Nº	Partido Político /Alianza	CANTIDAD DE VOTOS OBTENIDOS	
		SEÑORES NACIONALES	DEPUTADOS NACIONALES
501	UNITA POR LA LIBERTAD Y LA DIGNIDAD	0 0 4	0 0 4
501	FRENTE AMPLIO PROGRESISTA	0 0 6	0 0 7
502	FRENTE DE IZQ. Y DE TRABAJADORES-UNIDAD	0 0 1	0 0 1
503	JUNTOS POR EL CAMBIO	1 8 4	1 8 4
504	PRIMERO SANTA FE	0 0 2	0 0 2
505	SOMOS FUTURO	0 0 3	0 0 3
506	PODEMOS	0 0 4	0 0 4
507	SOBERANIA POPULAR	0 0 1	0 0 1
508	FRENTE DE TODOS	0 5 5	0 5 5
VOTOS EN BLANCO (señaladas en azul)		0 0 6	0 0 8
VOTOS NULOS (señaladas en celeste)		0 0 7	0 0 7
VOTOS RECURRIDOS (señaladas por categoría)		0 0 3	0 0 0
VOTOS DE IDENTIDAD IMPUGNADA (se señalan las categorías que no tienen votos)		0 0 0	0 0 0

FIGURA 3.2: Grilla de votos extraída buscando el contorno de mayor área.

3.2.3. Detección de líneas de la grilla de votos

El objetivo de este proceso es identificar las cuatro líneas verticales y las quince líneas horizontales que delimitan la grilla con los votos, con el propósito de posteriormente trabajar con cada renglón de la misma. Para llevar a cabo esta tarea, se emplea un enfoque simplificado para la detección de líneas, similar al utilizado en Lamagna (2016). Dado que la grilla se encuentra alineada verticalmente, se pueden utilizar las proyecciones de la escala de grises sobre los ejes x e y para detectarlas. Al sumarlos por eje, se pueden observar picos de valores donde se encuentran las líneas horizontales y verticales. Posteriormente, se selecciona un umbral de corte por cada eje, siendo el mismo el promedio de cada eje menos dos desvíos estándar. La figura 3.3 muestra las proyecciones obtenidas con los umbrales por cada eje.

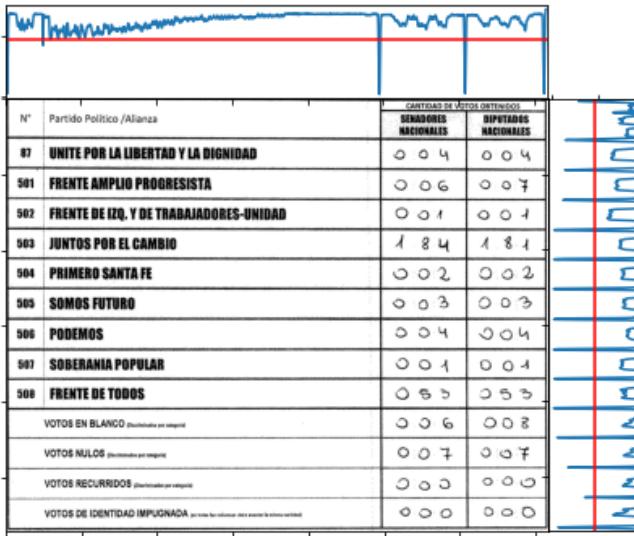


FIGURA 3.3: Proyecciones de los ejes de la grilla de votos. En rojo se marca el umbral de corte.

Sin embargo, aunque se seleccionen aquellos píxeles que se encuentren por debajo del umbral, existe más de un píxel por cada pico. Siguiendo con el ejemplo, en el eje x se obtienen los siguientes píxeles que se encuentran en los “picos”:

```
array([    3,     4,     5,     6,     7,   100,   119,   120,   988,
        989,   990,   991,   992,  1215,  1216,  1217,  1218,  1219,
      1423,  1424,  1425,  1426,  1427])
```

Con la estrategia del umbral no se obtienen las 4 líneas que se desean detectar sobre el eje x . No obstante, se puede aplicar un clustering jerárquico sobre los índices obtenidos y luego calcular el índice promedio de cada clúster para tomarlo como único representante. El proceso se repite de la misma manera sobre el eje y . Esta última modificación sobre el trabajo realizado en (Lamagna, 2016) asegura tener un único píxel por línea. La figura 3.4 muestra la segmentación detectada mediante el proceso descrito.




FIGURA 3.4: Grilla detectada (en verde) utilizando el umbral por sobre las proyecciones y su posterior agrupamiento con clustering jerárquico.

3.2.4. Segmentación de dígitos

Una vez obtenida la grilla, se itera por cada renglón obteniendo los rectángulos que contienen los votos, ignorando el primero que contiene los títulos de la grilla. La figura 3.5 muestra un renglón de la grilla obtenida.



FIGURA 3.5: Primer renglón extraído de la grilla de votos

Por cada uno de los renglones compuestos por las tres imágenes, se procede a extraer los dígitos de la cantidad de votos obtenidos por senadores y diputados, siendo la segunda y tercera imagen respectivamente. El proceso inicia aplicando un desenfoque gaussiano para suavizar la imagen y eliminar posibles secciones consideradas como ruido. El resultado de este paso se muestra en la figura 3.6.




FIGURA 3.6: Dígitos después del desenfoque gaussiano

A continuación, se aplica un umbral adaptativo para obtener una máscara binaria que resalta los píxeles que contienen la información escrita en la imagen. La figura 3.7 muestra la máscara obtenida.



FIGURA 3.7: Máscara obtenida al aplicar umbral adaptativo

Posteriormente, se emplea el análisis de componentes conectados (Bolelli et al., 2019) sobre la máscara generada en el paso anterior. Esto permite identificar las diferentes regiones conectadas presentes en la imagen binaria. Se filtran aquellos componentes detectados cuya cantidad total de píxeles sea inferior al 1.5 % de los píxeles totales de la máscara, así como aquellos que contengan más del 20 % de los píxeles totales de la máscara. Es importante destacar que los umbrales utilizados para esta depuración fueron determinados mediante experimentación. Este proceso tiene como objetivo eliminar componentes que sean ruido. Los componentes conectados identificados mediante este método se muestran en la figura 3.8.



FIGURA 3.8: Máscara con componentes conectados detectados

El siguiente paso consiste en generar un rectángulo contenedor para cada uno de los componentes identificados, tal como se ilustra en la figura 3.9.



FIGURA 3.9: Dígitos delimitados mediante rectángulos contenidos de los componentes conectados.

A través de la delimitación lograda se extraen los dígitos de la imagen original, obteniendo imágenes individuales de cada uno de ellos. Un ejemplo concreto de los dígitos adquiridos mediante este proceso se exhibe en la figura 3.10.



FIGURA 3.10: Dígitos detectados en el primer bloque de votos

El siguiente paso consiste en encuadrar las imágenes de los dígitos obtenidos para garantizar que los dígitos se presenten de manera estandarizada, lo que facilita su posterior procesamiento y análisis. El algoritmo utilizado consta de los siguientes pasos:

- Se determina si la imagen es más alta que ancha o más ancha que alta. Esto se hace comparando el número de filas y columnas de la matriz.
- Si la imagen es más alta que ancha, se agregan píxeles de relleno en los lados izquierdo y derecho de la imagen para hacerla cuadrada. Si la imagen es más ancha que alta, se agrega relleno en la parte superior e inferior.
- La cantidad de píxeles de relleno agregados a cada lado depende de la diferencia entre las dimensiones de la imagen original y el lado más corto del cuadrado. Si la diferencia es par, se agrega la misma cantidad de píxeles en cada lado. Si la diferencia es impar, se agrega un píxel extra en un lado para mantener la imagen centrada.
- Se aplica el relleno a la matriz original, lo que la convierte en una matriz cuadrada. El relleno se realiza asignando un valor constante a los píxeles adicionales, y en este caso, se utiliza el valor 255, que representa el color blanco.

La figura 3.11 muestra un ejemplo del resultado que se obtiene al aplicar el proceso de encuadre sobre los dígitos detectados.



FIGURA 3.11: Dígitos en formato cuadrado utilizando el proceso de encuadre.

El proceso culmina con la creación de un conjunto de datos que recopila información sobre los resultados electorales. Este conjunto de datos está compuesto por registros que representan a los diferentes partidos políticos, y su asignación a cada partido se determina en función del orden de las filas en la tabla de votos. Cada registro incluye detalles importantes, como los dígitos que representan los votos emitidos y el tipo de voto registrado, que puede ser para senadores o diputados. El objetivo principal de llevar a cabo este proceso es contar con un conjunto de datos completo y bien estructurado, el cual será empleado para entrenar y validar los modelos que se utilizarán más adelante. Al reunir esta información electoral en un solo lugar, se crea una base de datos coherente y lista para ser utilizada en tareas de análisis, predicción y toma de decisiones relacionadas con el proceso electoral.

3.3. Análisis del conjunto de datos

Una vez que se ha completado el proceso de extracción y segmentación de los dígitos, se procede a realizar un análisis exploratorio de los datos. Este análisis tiene como objetivo detectar posibles errores o inconsistencias en los datos extraídos, que puedan afectar la calidad de los modelos de aprendizaje automático que se construirán a partir de ellos.

El cuadro 3.1 muestra algunos registros del conjunto de datos, que incluye información como el número del telegrama, el partido político, el tipo de voto (senadores o diputados) y los dígitos correspondientes a cada candidato.

CUADRO 3.1: Ejemplo de registros del conjunto de datos. Cada fila representa la cantidad de votos obtenidos por un partido político y tipo.

Telegrama	Partido	Tipo	Dígitos	# Dígitos
2100100026X	Unite	Diputados	○○4	3
2100100026X	Unite	Senadores	□○○4	4
2100100067X	Frente de Todos	Diputados	○○○○	4
2100100067X	Frente de Todos	Senadores	○○○	3

Se pueden detectar errores evidentes en la tabla presentada. En primer lugar, se puede observar que en la columna donde solamente deben aparecer las imágenes de los dígitos, en el segundo registro existe una imagen de una línea horizontal, lo cual no es correcto. Además, también se detectan dígitos mal escritos o enmendados, como los que se encuentran en los dos últimos registros.

Para corregir estas extracciones incorrectas, se calculan dos columnas adicionales que contienen las proporciones mínimas y máximas de píxeles blancos en las imágenes para cada voto. Estas proporciones permiten establecer

un umbral de confianza para las extracciones, de tal manera que aquellas imágenes con proporciones de píxeles blancos fuera de los límites establecidos son descartadas.

Para visualizar de manera más clara la distribución de estas proporciones, se generan histogramas que muestran la frecuencia de cada valor dentro del rango establecido. La figura 3.12 presenta estos histogramas para las proporciones mínimas y máximas de píxeles blancos en las imágenes del conjunto de datos.




FIGURA 3.12: Histogramas de proporciones de píxeles blancos por dígito.

La cola derecha de la distribución de 3.12b presenta un pico anormal en el extremo cercano a 1. Al eliminar aquellas imágenes de dígitos que posean más de un 95 % de píxeles blancos, se logran descartar los casos de líneas como la vista en el cuadro 3.1. Por otro lado, al eliminar aquellas imágenes que posean menos del 50 % de píxeles blancos, se logran descartar los casos de escritura incorrecta.

El siguiente punto a analizar es el tamaño de las imágenes. Como se muestra en el cuadro 3.1, las imágenes no fueron estandarizadas en cuanto a tamaño. De manera análoga a la variable de proporción de píxeles blancos, se calculan las variables de mínimo y máximo tamaño por voto. El cuadro 3.2 muestra los estadísticos descriptivos de las mismas.

CUADRO 3.2: Estadísticos descriptivos del mínimo y máximo tamaño de las imágenes de los votos.

Variable	Promedio	Desvío	Mínimo	Mediana	Máximo
Tamaño mínimo	38.35	9.61	13	37	621
Tamaño máximo	44.80	10.73	18	43	621

Al analizar aquellos registros que poseen los valores extremos en cuanto a mínimo y máximo de tamaño, se encuentran telegramas que fueron cargados de forma incorrecta (ver anexo A.2) o con una caligrafía en la cual los dígitos no están separados entre sí, provocando que la segmentación por el

análisis de componentes conectados falle (ver anexo A.3). Se eliminan estos casos filtrando por aquellos registros que se encuentren por fuera de la media más/menos cuatro desvíos estándar.

Una vez finalizada la etapa de análisis y limpieza, se exportan los dígitos extraídos en un formato similar al conocido conjunto de datos *MNIST* junto con la etiqueta correspondiente. Este conjunto de datos será denominado *TDS* (conjunto de datos de telegramas) a partir de este momento. El conjunto de datos *TDS* consta de un total de 170.718 imágenes de dígitos cuadradas con sus dimensiones originales, es decir, no se han estandarizado en una dimensión específica. Esta decisión se tomó intencionalmente, ya que podría permitir una mayor flexibilidad en el perfeccionamiento, procesamiento y análisis de los mismos en trabajos futuros. La figura 3.13 muestra una previ visualización del conjunto de datos *TDS*.



FIGURA 3.13: Muestra de 100 dígitos del conjunto de datos TDS

3.4. Diseño experimental

Se llevaron a cabo experimentos con el fin de evaluar el desempeño de dos redes neuronales convolucionales, la ResNet18 (He et al., 2016) y la LeNet-8 (LeCun et al., 1998), para cada una de las técnicas de adaptación de dominio que fueron descritas en el capítulo 2. Además, como modelo de referencia, se entrenaron ambas redes sin ninguna técnica de adaptación. De esta manera, se busca comparar el rendimiento de las redes con y sin técnicas de adaptación de dominio, para determinar cuál técnica es la más adecuada para el problema en cuestión.

Las tecnologías utilizadas son:

- Python como lenguaje de programación general.
- PyTorch (Paszke et al., 2019) para la implementación de los modelos.
- PyTorch Lightning (Falcon y The PyTorch Lightning team, 2019) para simplificar el entrenamiento de los modelos.

- TLLIB (Jiang, Shu y Long, 2020) para aplicar las técnicas de adaptación de dominio.

3.4.1. Metodología de entrenamiento

Para entrenar modelos mediante adaptación de dominio, se necesitan dos conjuntos de datos: uno etiquetado, llamado origen, y otro sin etiquetar, llamado destino. En los experimentos llevados a cabo, se utilizó el conjunto de datos *MNIST* como origen y el conjunto de datos *TDS* como destino. Durante cada iteración de entrenamiento, se proporcionó un lote de 1024 imágenes del conjunto de datos de origen y otro igual del conjunto de datos de destino. Se realizaron tres particiones para cada conjunto de datos:

- Entrenamiento (70 % de cada conjunto de datos): utilizado para entrenar la LeNet-8 y ResNet18 en cada época.
- Validación (15 % de cada conjunto de datos): utilizado para calcular los mejores hiperparámetros del modelo.
- Test (15 % de cada conjunto de datos): utilizado para calcular las métricas y gráficos finales del modelo entrenado.

Los modelos se entrenaron utilizando Stochastic Gradient Descent (SGD) (Sutskever et al., 2013) utilizando nesterov, 0.9 como momento y 0.001 de weight decay, parámetros recomendados para este tipo de aplicaciones.

3.4.2. Selección y optimización del modelo

La optimización de hiperparámetros se realizó utilizando la librería Optuna (Akiba et al., 2019). Se ejecutaron 30 rondas de optimización con 10 épocas de entrenamiento por cada experimento. En cada uno de los experimentos, se optimizaron los hiperparámetros para minimizar la función de pérdida de cada modelo. El cuadro 3.3 muestra los rangos de búsqueda para cada modelo, incluyendo el modelo de referencia (baseline, sin adaptación de dominio).

CUADRO 3.3: Rango de hiperparámetros optimizados para cada modelo.

	<i>DANN</i>	<i>ADDA</i>	<i>DANN+BSP</i>	<i>MDD</i>	<i>AFN</i>	<i>Sin AD</i>
η_0	[1e-4, 0.1]	[1e-4, 0.1]	[1e-4, 0.1]	[1e-4, 0.1]	[1e-4, 0.1]	[1e-4, 0.1]
λ	[0.5, 2]	[0.5, 2]	[0.5, 2]	[0.5, 2]	[0.001, 0.1]	-
β	-	-	[1e-5, 0.1]	-	[0.0, 0.1]	-
γ	-	-	-	[1, 10]	-	-
Δ_r	-	-	-	-	[0.01, 5]	-
# Blocks	-	-	-	-	[1, 4]	-
Dropout	-	-	-	-	[0.3, 0.7]	-

Se implementó una disminución del learning rate en cada iteración de cada época, mediante la fórmula 3.2.

$$\eta(t) = \eta_0 * (1 + \gamma_\eta * t)^{-\theta} \quad (3.2)$$

donde se optaron los valores de $\gamma_\eta = 0,001$ y $\theta = 0,25$.

3.5. Métricas de evaluación

Los modelos optimizados serán evaluados con distintas métricas en tiempo de test, descritas en las siguientes sub-secciones del capítulo. Las mismas pretenden evaluar qué tan buenos son los modelos respecto a la tarea de clasificación y qué capacidad de adaptación de dominio poseen.

3.5.1. Métricas de clasificación

Tasa de acierto

La métrica de tasa de acierto (o *accuracy*) permite identificar qué tan cerca o lejos están los dígitos predichos respecto a los de referencia. Es el ratio de predicciones correctas sobre las totales.

$$\text{Tasa de Acierto}(y, \hat{y}) = \frac{1}{n} \sum_{i=0}^{n-1} 1(\hat{y}_i = y_i) \quad (3.3)$$

donde:

- n : es la cantidad de observaciones totales.
- y_i : es la clase de dígito de la i -ésima observación correspondiente al real.
- \hat{y}_i : es la clase de dígito predicho para la i -ésima observación.
- $1(x)$: es la función indicadora.

F_1

La métrica F_1 es una media armónica de otras dos: *precisión* y *sensibilidad*. De manera simplificada, la primera muestra la capacidad del modelo de no etiquetar como positivo una observación que es negativa y la segunda muestra la capacidad del modelo de encontrar todas las observaciones positivas.

La *sensibilidad* consiste en calcular la tasa de predicciones positivas correctas de la clase respecto al total de predicciones positivas de la clase.

$$\text{Precision}(y, \hat{y}) = \frac{TP}{TP + FP} \quad (3.4)$$

donde:

- TP : es la cantidad de verdaderos positivos.

- FP : es la cantidad de falsos positivos.

Por otro lado, la *sensibilidad* consiste en calcular la tasa de predicciones positivas correctas de la clase respecto al total de predicciones correctas de la clase.

$$\text{Sensibilidad}(y, \hat{y}) = \frac{TP}{TP + FN} \quad (3.5)$$

donde:

- TP : es la cantidad de verdaderos positivos.
- FN : es la cantidad de falsos negativos.

Las dos métricas mencionadas anteriormente pueden ser combinadas en una sola denominada F_β . El valor de β permite asignar un peso distinto a la precisión o a la sensibilidad dentro del promedio armónico. Cuando $\beta = 1$, ambas poseen el mismo peso.

$$F_\beta(y, \hat{y}) = (1 + \beta^2) \times \frac{\text{precision}(y, \hat{y}) \times \text{sensibilidad}(y, \hat{y})}{\beta^2 \times \text{precision}(y, \hat{y}) + \text{sensibilidad}(y, \hat{y})} \quad (3.6)$$

El rango de valores es de $[0, 1]$, donde 1 corresponde a un clasificador que funciona sin errores.

Intersección sobre unión

Otra forma de evaluar al clasificador es mediante la *intersección sobre unión* (IoU por sus siglas en inglés). Consta de calcular la cantidad de dígitos únicos predichos por sobre la cantidad de dígitos únicos reales. Por ejemplo, para un telegrama y un partido el clasificador predice 189 votos cuando lo real es 180, el *IoU* viene dado por:

$$\begin{aligned} IoU(\{1, 8, 0\}, \{1, 8, 9\}) &= \frac{|\{1, 8, 0\} \cap \{1, 8, 9\}|}{|\{1, 8, 0\} \cup \{1, 8, 9\}|} \\ &= \frac{|\{1, 8\}|}{|\{1, 8, 0, 9\}|} \\ &= \frac{2}{4} \\ &= 0,5 \end{aligned} \quad (3.7)$$

De forma general: sea y_i el dígito i -ésimo del voto real y de longitud n , \hat{y}_j el dígito j -ésimo del voto predicho por el modelo \hat{y} de longitud m , entonces la métrica viene dada por:

$$IoU(y, \hat{y}) = \frac{|\{y_i\} \cap \{\hat{y}_j\}|}{|\{y_i\} \cup \{\hat{y}_j\}|} \quad \forall i \in \{1, \dots, n\}, \forall j \in \{1, \dots, m\} \quad (3.8)$$

El rango de valores es de $[0, 1]$, donde 1 corresponde a un clasificador que funciona sin errores.

3.5.2. Métricas de adaptación

Distancia \mathcal{A}

La distancia \mathcal{A} mide la similaridad entre dos distribuciones. Es muy utilizada para analizar los espacios latentes de clasificadores en problemas de adaptación de dominio (Ben-David et al., 2006). La métrica viene dada por:

$$dist_{\mathcal{A}} = 2(1 - 2\epsilon), \quad (3.9)$$

donde ϵ es el error en test de un clasificador entrenado para identificar el dominio de los ejemplos (origen o destino), por lo que su rango de valores es de cero al uno. Cuando el error de clasificación es bajo, significa que hay diferencias significativas entre las dos distribuciones, haciendo que $dist_{\mathcal{A}}$ sea grande y viceversa.

En la figura 3.14 se muestran posibles casos de distribuciones de dominios. En la sub-figura 3.14a las distribuciones de dominios son significativamente diferentes entre sí, por lo tanto $dist_{\mathcal{A}} \approx 2$. Por el contrario, en la sub-figura 3.14b las distribuciones de dominios son similares entre sí, por lo que se espera que $dist_{\mathcal{A}} \approx 0$.

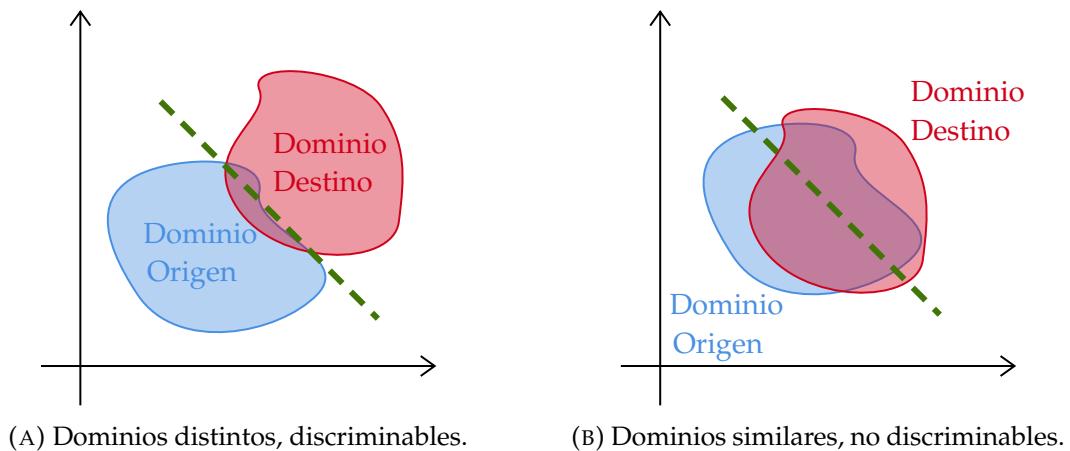


FIGURA 3.14: Ejemplos de distribuciones de dominios.

Durante el proyecto se utiliza como clasificador una regresión logística a fin de calcular la distancia \mathcal{A} .

Discrepancia de Medias Máxima

La discrepancia de medias máxima (MMD por sus siglas en inglés) es una prueba estadística basada en *kernels* que se utiliza para determinar si dos distribuciones dadas son iguales midiendo la distancia entre ellas (Gretton et al., 2012). Dadas las distribuciones P y Q sobre un conjunto \mathcal{X} y un mapa

de características $\phi : \mathcal{X} \rightarrow \mathcal{H}$ donde \mathcal{H} es un conjunto de destino, MMD se define como:

$$MMD^2(P, Q) = \|\mathbb{E}_{\mathbf{x} \sim P}[\phi(\mathbf{x})] - \mathbb{E}_{\mathbf{y} \sim Q}[\phi(\mathbf{y})]\|_{\mathcal{H}}^2 \quad (3.10)$$

Por ejemplo, si el mapa de características es $\phi(x) = x$ y $\mathcal{X} = \mathcal{H} = \mathbb{R}^d$, MMD se calcula como:

$$\begin{aligned} MMD^2(P, Q) &= \|\mathbb{E}_{\mathbf{x} \sim P}[\phi(\mathbf{x})] - \mathbb{E}_{\mathbf{y} \sim Q}[\phi(\mathbf{y})]\|_{\mathcal{H}}^2 \\ &= \|\mathbb{E}_{\mathbf{x} \sim P}[\mathbf{x}] - \mathbb{E}_{\mathbf{y} \sim Q}[\mathbf{y}]\|_{\mathbb{R}^d}^2 \\ &= \|\mu_P - \mu_Q\|_{\mathbb{R}^d}^2, \end{aligned} \quad (3.11)$$

de forma que MMD es la distancia entre las medias de las distribuciones. No obstante, evaluarlas de esta manera puede generar que distribuciones con distinta varianza, kurtosis, etc. sean consideradas como iguales. Se puede aplicar el *kernel trick* para calcular MMD con distancias más complejas. Dado $k(x, y) = \langle \phi(x), \phi(y) \rangle_{\mathcal{H}}$, MMD se calcula como:

$$\begin{aligned} MMD^2(P, Q) &= \|\mathbb{E}_{\mathbf{x} \sim P}[\phi(\mathbf{x})] - \mathbb{E}_{\mathbf{y} \sim Q}[\phi(\mathbf{y})]\|_{\mathcal{H}}^2 \\ &= \mathbb{E}_{\mathbf{x}, \mathbf{x}' \sim P} k(\mathbf{x}, \mathbf{x}') - \mathbb{E}_{\mathbf{y}, \mathbf{y}' \sim Q} k(\mathbf{y}, \mathbf{y}') - 2\mathbb{E}_{\mathbf{x} \sim P, \mathbf{y} \sim Q} k(\mathbf{x}, \mathbf{y}) \end{aligned} \quad (3.12)$$

Se utilizó la librería TorchDrift (Viehmann, Antiga y Marcolini, 2021) para implementarla en la evaluación de los modelos utilizando como *kernel* funciones de base radial.

Capítulo 4

Análisis de resultados

A lo largo del presente capítulo, se analizarán los resultados obtenidos a partir de los experimentos planteados en el capítulo anterior. Se detallarán las métricas obtenidas, se visualizarán los espacios latentes \mathbf{z} generados por la parte convolucional de las redes y se analizarán los errores que surgen de aplicar los modelos a los telegramas.

4.1. Análisis de métricas

Los experimentos realizados arrojaron los resultados mostrados en el cuadro 4.1. Las métricas referidas a la capacidad de clasificación (tasa de acierto, F_1) son evaluadas sobre la partición de test del conjunto de datos de origen donde se conocen las etiquetas a ciencia cierta (MNIST). Por otro lado, las métricas de adaptación (MMD , Dist. \mathcal{A}) son evaluadas sobre los espacios latentes que los modelos generaron para las particiones de test de ambos conjuntos de datos.

Es importante destacar que el mejor modelo es aquel que tiene tanto la mejor capacidad de clasificación como la mejor adaptación a nuevos conjuntos de datos. Las métricas de clasificación deben ser maximizadas y las de adaptación deben ser minimizadas.

CUADRO 4.1: Métricas de los experimentos realizados. Entre paréntesis se encuentra la posición que ocupa dentro del top 3 de la columna.

AD	Modelo	Tasa de acierto		F_1	MMD	Dist. \mathcal{A}
-	ResNet	(2)	0.9885	(2) 0.9883	0.0632	1.9306
	LeNet		0.9811	0.9810	0.0469	1.9515
DANN	ResNet	(1)	0.9890	(1) 0.9890	0.1379	1.9776
	LeNet		0.9822	0.9821	(3) 0.0090	1.6774
ADDA	ResNet		0.9476	0.9485	0.0165	1.8495
	LeNet		0.9191	0.9184	0.0399	1.8495
DANN+BSP	ResNet		0.9780	0.9777	0.0409	1.7888
	LeNet		0.9859	0.9857	(2) 0.0051	(3) 1.6369
MDD	ResNet	(3)	0.9864	(3) 0.9863	0.0615	1.8987
	LeNet		0.9856	0.9854	0.0399	1.7468
AFN	ResNet		0.9829	0.9827	(1) 0.0040	(1) 1.0886
	LeNet		0.9862	0.9859	0.0117	(2) 1.5747

Según los resultados presentados en la tabla anterior, se puede concluir que los modelos entrenados con DANN muestran un desempeño ligeramente superior en términos de tasa de acierto y F_1 en comparación con los modelos baseline (0,5 % de mejora). Sin embargo, es importante destacar que esta diferencia en el rendimiento puede no ser significativa, por lo que puede considerarse prácticamente nula.

El modelo ResNet18, utilizando AFN, demuestra ser el modelo que combina mejor las métricas de clasificación y adaptación. A pesar de esto, se destaca que los modelos LeNet entrenados con DANN y AFN obtuvieron buenas métricas en general, lo que sugiere que en ocasiones, un modelo más complejo no necesariamente garantiza un mejor rendimiento.

Los modelos se aplicaron a todos los telegramas, y se calculó el promedio de IoU por telegrama utilizando el método descrito en el capítulo 3. Además, se determinó la cantidad promedio de aciertos por telegrama utilizando las etiquetas transcritas en el centro de cómputo, asumiendo que hay pocos errores en ellas. El cuadro 4.2 muestra el IoU promedio y la cantidad de aciertos promedios obtenidos para los telegramas de prueba.

CUADRO 4.2: IoU promedio y cantidad promedio de aciertos por telegrama obtenidos al aplicar los modelos a los telegramas.

AD	Modelo	<i>IoU</i> prom.	# aciertos prom.	% aciertos prom.
-	ResNet	0.4494	4	22 %
	LeNet	0.4715	6	33 %
DANN	ResNet	0.6941	12	67 %
	LeNet	0.7024	12	67 %
ADDA	ResNet	0.6763	11	61 %
	LeNet	0.6406	10	56 %
DANN+BSP	LeNet	0.6695	11	61 %
	ResNet	0.6515	11	61 %
MDD	ResNet	0.5451	8	44 %
	LeNet	0.5801	9	50 %
AFN	ResNet	0.7486	13	72 %
	LeNet	0.6493	11	61 %

Analizando el cuadro anterior, se confirma la elección del mejor modelo ResNet18 con AFN. Es importante destacar que independientemente de la técnica de adaptación utilizada, todos los modelos presentan tasas de acierto marcadamente superiores que aquellos modelos entrenados únicamente con MNIST. Esto sugiere que la adaptación de dominio es fundamental para obtener un mejor rendimiento en la tarea de clasificación de telegramas. Los modelos entrenados con técnicas de adaptación logran generalizar mejor y son más efectivos en la tarea de reconocimiento de los patrones presentes en los telegramas, incluso en presencia de ruido y variaciones en los datos de entrada. Las figuras 4.1 y 4.2 muestran la distribución de aciertos por telegrama obtenida utilizando el modelo baseline y el mejor resultante para LeNet5 y ResNet18 respectivamente.

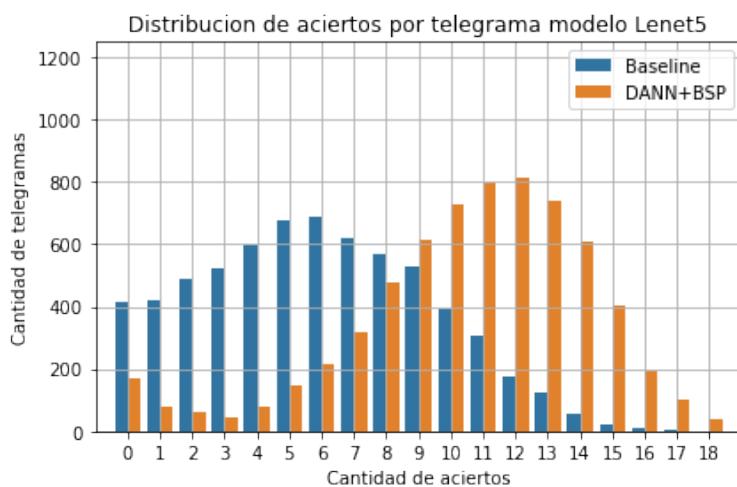


FIGURA 4.1: Distribución de cantidad de aciertos por telegrama utilizando el modelo baseline (sin adaptación de dominio) y la mejor técnica de adaptación de dominio obtenida para LeNet5.

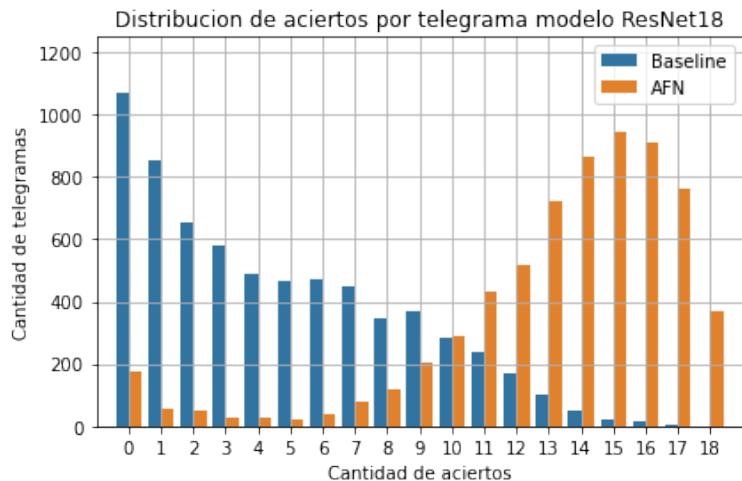


FIGURA 4.2: Distribución de cantidad de aciertos por telegrama utilizando el modelo baseline (sin adaptación de dominio) y la mejor técnica de adaptación de dominio obtenida para ResNet18.

Otro punto a resaltar es que cuando no se utiliza adaptación de dominio en la ResNet18, la cantidad de aciertos promedio por telegrama es incluso peor que la de LeNet5. Esto puede deberse a que, al ser una red mucho más grande y con más capacidad de aprendizaje, sobreajusta al MNIST no pudiendo generalizar al TDS.

4.2. Análisis de los espacios latentes

Una forma común de visualizar los espacios latentes generados es mediante una técnica de reducción de dimensionalidad, como Aproximación y Proyección Uniforme de Variedad UMAP (McInnes, Healy y Melville, 2018). Es una técnica no lineal que se utiliza para visualizar estructuras de datos complejas en un espacio de menor dimensión. Al visualizar los espacios latentes utilizando UMAP, se pueden observar patrones y relaciones en los datos que de otra manera serían difíciles de detectar. Al comparar las distribuciones de los espacios latentes generados por un modelo para diferentes conjuntos de datos, se pueden identificar las similitudes y diferencias entre los dominios, lo que puede ser útil para evaluar la capacidad de adaptación de dominio del modelo. En las siguientes subsecciones se analizarán las representaciones UMAP de los espacios latentes obtenidos por cada modelo entrenado.

4.2.1. LeNet

La figura 4.3 a continuación contiene las representaciones UMAP obtenidas de los espacios latentes generados por todos los modelos LeNet.

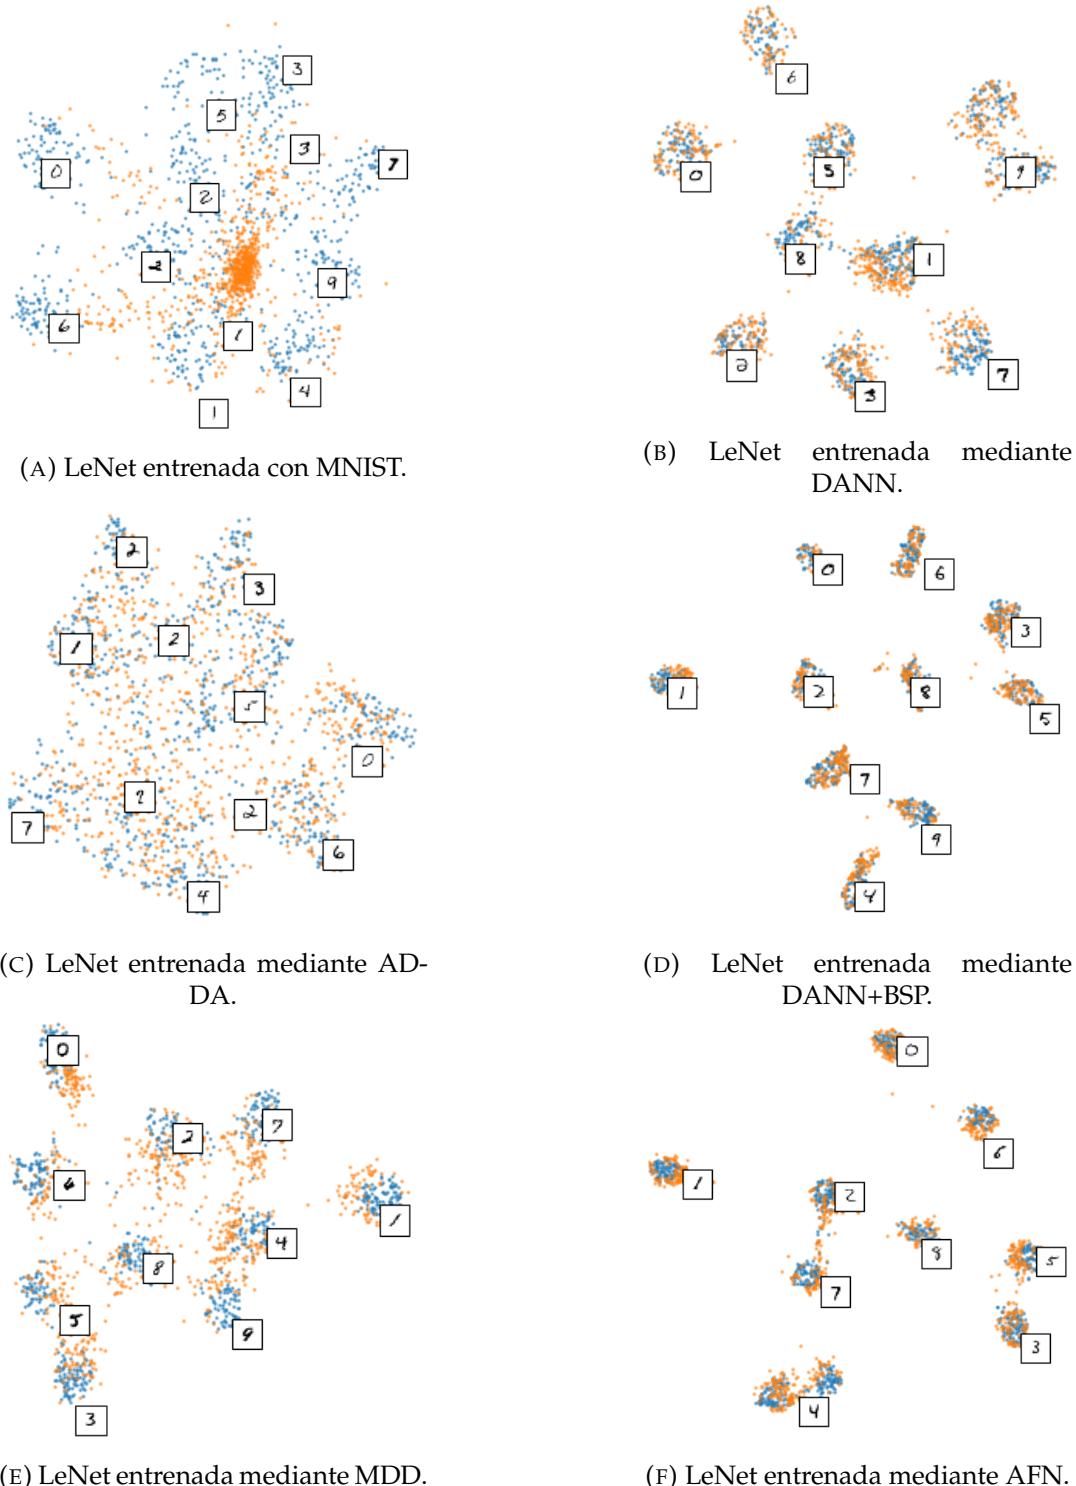


FIGURA 4.3: Representación UMAP de las características aprendidas de los modelos LeNet5. Los puntos azules representan observaciones de MNIST y los naranjas de TDS. Los carteles con dígitos son visualizaciones de muestras aleatorias extraídas del conjunto de datos MNIST, lo que permite comprender su ubicación en la representación UMAP.

Se pueden observar los siguientes resultados:

- Entrenar el modelo solo con MNIST no permite una buena generalización para TDS, como se muestra en la figura 4.3a.
- Con el entrenamiento mediante ADDA o MDD se comienzan a generar agrupaciones en MNIST, pero no logran generarse de la misma manera en TDS, como se puede apreciar en las figuras 4.3c y 4.3e.
- Al entrenar el modelo mediante DANN, se generan agrupaciones similares para ambos conjuntos de datos, como se muestra en la figura 4.3b.
- Finalmente, al utilizar la técnica de entrenamiento DANN con penalización BSP y AFN, se generan agrupaciones similares y más densas para ambos conjuntos de datos, tal como se muestra en las figuras 4.3d y 4.3f.

En conclusión, se puede afirmar que la técnica de adaptación de dominio utilizada tiene un gran impacto en el rendimiento de un modelo LeNet debido a su estructura simple. Entre las diferentes técnicas evaluadas, se puede observar que DANN+BSP y AFN son las que proporcionan una mejor capacidad de adaptación al modelo LeNet. En general, estos resultados resaltan la importancia de seleccionar cuidadosamente la técnica de adaptación de dominio adecuada para un modelo dado a fin de lograr un rendimiento óptimo en diferentes escenarios de aplicación.

4.2.2. ResNet

La figura 4.4 a continuación contiene las representaciones UMAP obtenidas de los espacios latentes generados por todos los modelos ResNet.




FIGURA 4.4: Representaciones UMAP de los espacios latentes de los modelos ResNet18. Los puntos azules representan observaciones de TDS y los naranjas de MNIST. Los carteles con dígitos son visualizaciones de muestras aleatorias extraídas del conjunto de datos MNIST, lo que permite comprender su ubicación en la representación UMAP.

Al analizar las representaciones UMAP de los espacios latentes obtenidos por los modelos ResNet, se pueden observar los siguientes resultados:

- En contraste con los modelos LeNet, la ResNet es más eficaz en la extracción de características *out of the box*, lo que le permite generalizar mejor sin necesidad de técnicas de adaptación de dominio (figura 4.4a).
- La aplicación de técnicas de adaptación de dominio como DANN, DANN con penalización BSP y ADDA mejora la capacidad de generalización, pero no de forma significativa en comparación con las mejoras obtenidas con LeNet (figuras 4.4b, 4.4d y 4.4c).
- El uso de MDD parece disminuir la capacidad de generalización (figura 4.4e).
- La aplicación de AFN potencia la generalización de la ResNet, obteniendo representaciones de los espacios latentes prácticamente idénticas para ambos conjuntos de datos (figura 4.4f).

En general, estas representaciones permiten visualizar los resultados obtenidos a partir de las métricas de adaptación descritas en el cuadro 4.1 de la sección anterior.

4.3. Análisis de errores

Los errores de predicción de los modelos pueden ser analizados mediante los histogramas de la métrica *IoU* que se obtienen de aplicar los modelos a los telegramas.

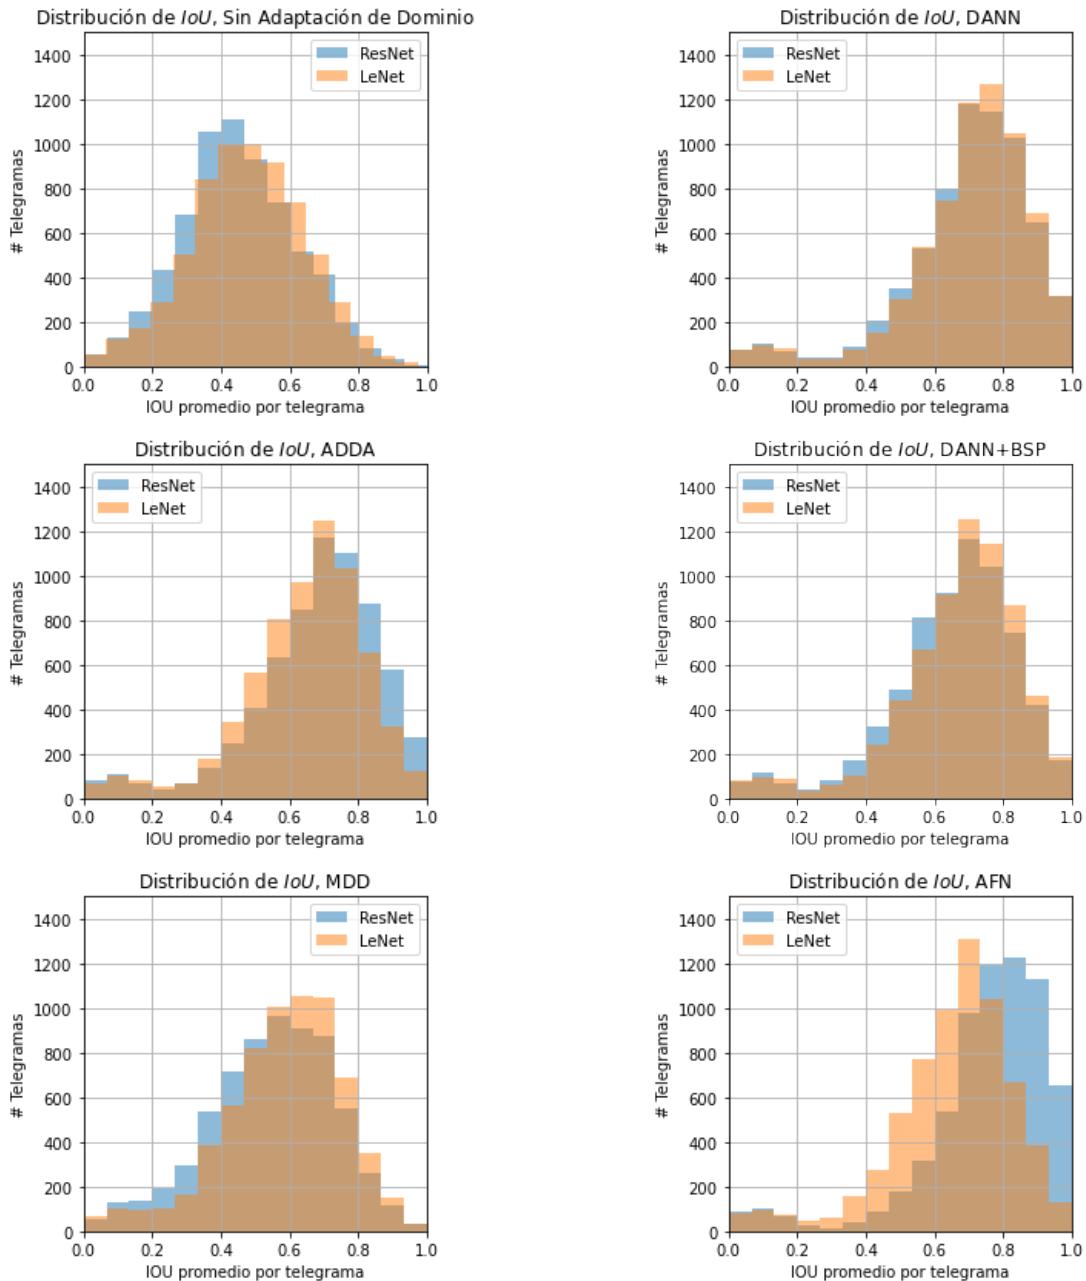


FIGURA 4.5: Histogramas de la métrica IoU promedio por telegrama por cada técnica AD y modelo.

Resulta interesante mencionar existen telegramas que son más difíciles de analizar que otros. Esto puede evidenciarse en los histogramas de la figura 4.5 donde se pueden observar un conjunto de observaciones que contienen valores entre $[0, 0.2]$ en todos los experimentos realizados. Luego de analizar cada uno de estos casos, se detectaron las siguientes situaciones:

- Telegramas cargados de forma errónea: ver ejemplo en el anexo A.2. Hay telegramas que corresponden a concejales locales en vez de legisladores nacionales.

- Telegramas correctos, pero por alguna cuestión la lógica de extracción de dígitos no funciona correctamente: ver ejemplo en el anexo A.3. Los dígitos están unidos sin dejar espacio entre ellos, lo que dificulta segmentarlos.
- Telegramas donde existen otros caracteres distintos a números: al ser un cuadro de texto libre sin formato, los jefes de mesa pueden escribir lo que deseen. Ver ejemplo en el anexo A.4 donde se representa el 0 a la izquierda con X.
- Telegramas de mesas donde la mayor cantidad de votos se las lleva un único partido y completan los votos a la izquierda con 0: al agregar los ceros a la izquierda, aumenta la probabilidad de que el modelo se equivoque con esos ceros que no aportan al número final. Ver ejemplo en el anexo A.5.

En los primeros dos puntos se describen problemas que fueron detectados en el proceso de ETL del capítulo 3. Estandarizar los telegramas agregando un casillero por cada dígito junto a mejorar el proceso de extracción de los mismos, supondrá una mejora considerable en las capacidades predictivas de los modelos.

El tercer punto presenta un problema dentro de la adaptación de dominio. La misma supone que, si bien los conjuntos de datos de origen y destino son diferentes, pero representan lo mismo, debe existir la misma cantidad de clases entre origen y destino. Al agregar uno o varios caracteres adicionales en TDS (como es el ejemplo donde representaban el 0 con una X), se está incumpliendo este supuesto.

El cuarto punto aumenta la probabilidad de error en los modelos debido a que el 0 a la izquierda no aporta significado alguno al número de la cantidad de votos que se desea predecir.

Estandarizar la carga de los telegramas por parte de los jefes de mesa mediante alguna capacitación permitiría reducir los errores de los puntos tres y cuatro en elecciones futuras.

Capítulo 5

Conclusiones

Esta tesis se enfocó en utilizar técnicas de adaptación de dominio para mejorar la digitalización de los votos en elecciones mediante redes neuronales entrenadas con diversos algoritmos de adaptación de dominio. En primera instancia, se desarrolló un proceso de Extracción, Transformación y Carga (ETL) de los telegramas que permitió segmentar cada uno de los dígitos y crear un conjunto de datos adecuado para la tarea de digitalización. Este proceso de ETL estandarizó los datos para que pudieran ser procesados y analizados de manera más efectiva.

En una siguiente etapa, tras realizar múltiples experimentos, se pudo determinar que la red ResNet18 entrenada mediante AFN es el modelo que tiene el mejor rendimiento en la tarea de digitalización de telegramas. Este resultado indica que el uso de modelos más complejos y profundos puede ser beneficioso en este tipo de tarea. Sin embargo, también se pudo comprobar que una red más simple, como la LeNet5 con AFN, tiene un rendimiento satisfactorio, lo que sugiere que no siempre es necesario utilizar modelos complejos para resolver tareas como esta.

En cuanto a la precisión obtenida al aplicar el mejor modelo a los telegramas de prueba, se alcanzó una precisión promedio del 73 %, sin haber estandarizado la casilla donde se escriben los dígitos. No obstante, se podría mejorar aún más el resultado si se dispusiera de un casillero por número a escribir, lo que permitiría evitar agregar ceros a la izquierda y, en consecuencia, aumentar la calidad del proceso de ETL de segmentación de dígitos. En este sentido, se espera que la implementación de esta mejora contribuya a mejorar la precisión de las predicciones.

Es importante destacar que la utilización de técnicas de adaptación de dominio en la tarea de digitalización de telegramas de elecciones es un campo de investigación en desarrollo, y aún existen diversas limitaciones que deben ser abordadas. No obstante, los resultados obtenidos en esta tesis son prometedores y sugieren que la adaptación de dominio puede ser una técnica útil para mejorar la digitalización de telegramas de elecciones en contextos de alta variabilidad.

Cabe señalar que los resultados obtenidos en esta tesis pueden tener implicaciones importantes en la automatización de procesos electorales, lo que puede mejorar la eficiencia y la transparencia de las elecciones. Con la digitalización de telegramas de manera efectiva, es posible mejorar la velocidad y la precisión del conteo de votos, lo que puede reducir la posibilidad de errores humanos y aumentar la confianza en los procesos electorales.

5.1. Trabajos Futuros

Existen diversas posibilidades de mejora y trabajos futuros que pueden llevarse a cabo para ampliar el alcance y la calidad de los resultados. A continuación, se detallan algunas posibles líneas de investigación futura:

- Mejora del proceso ETL: una de las limitaciones de la presente investigación es la calidad del conjunto de datos TDS, ya que presenta ciertas limitaciones en términos de segmentación de los dígitos en los telegramas. Por lo tanto, una posible línea de investigación futura es la mejora del proceso ETL para mejorar la segmentación de los dígitos y mejorar la calidad del conjunto de datos.
- Mejorar el proceso de post-procesamiento de las predicciones: En la implementación actual, no se realizó ningún tipo de post-procesamiento en las predicciones obtenidas por los modelos de aprendizaje automático. Sería útil explorar distintas opciones de post-procesamiento, como la validación de que la cantidad total de votos predichos por telegrama no supere el total que debe haber por mesa, o la validación de que la cantidad de votos por partido no supere el total de la mesa. También se podría considerar la utilización de otras técnicas de post-procesamiento, como la corrección de errores en las predicciones mediante la incorporación de información contextual adicional.
- Mejora de la estandarización de los telegramas: Como se mencionó en las conclusiones, la estandarización en la sección donde se escriben los dígitos podría mejorar aún más la precisión de los modelos, ya que mejoraría la calidad de los dígitos del TDS.
- Evaluación de otras técnicas de adaptación de dominio: En esta tesis se evaluaron algunas técnicas de adaptación de dominio, pero existen muchas otras técnicas que podrían ser útiles para mejorar la precisión de la digitalización de telegramas. Por lo tanto, una posible línea de investigación futura es la evaluación de otras técnicas de adaptación de dominio para comparar su efectividad con las técnicas utilizadas en esta investigación.
- Evaluación de modelos híbridos: Otra posible línea de investigación futura es la evaluación de modelos híbridos que combinen técnicas de adaptación de dominio con otros métodos de mejora de la precisión en la tarea de digitalización de telegramas. Por ejemplo, se podría explorar la combinación de redes neuronales con técnicas de procesamiento de imágenes para mejorar la calidad de los datos.

En conclusión, existen varias líneas de investigación desprendidas de la tesis actual que pueden ser exploradas para mejorar la precisión de los modelos que deben aplicarse en un conjunto de datos con características distintas que del que se entrenó. Estas mejoras pueden ser importantes para aumentar la confianza en los procesos electorales y mejorar la transparencia y la eficiencia en el conteo de votos.

Apéndice A

Anexo: Telegramas

A.1. Ejemplo de telegrama

Correo Argentino

DESTINATARIO:
CON COPIA: JUNTA ELECTORAL NACIONAL - Distrito - SANTA FE
DIRECCION NACIONAL ELECTORAL

HOJA 1/1

DISTRITO SANTA FE	SECCION / CIRCUITO 1 - BELGRANO 402 - ARMSTRONG	MESA N°: 1	ELECCIONES GENERALES - 14 DE NOVIEMBRE DE 2021 TELEGRAMA DEL PRESIDENTE DE MESA
CANTIDAD DE SOBRES UTILIZADOS EXTRAIOS DE LA URNA		2 8 3	
TOTAL DE ELECTORES QUE HAN VOTADO SEGUN EL PADRON		2 8 3	
DIFERENCIA ENTRE LAS ANTERIORES		0 0 0	

Nº	Partido Político /Alianza	CANTIDAD DE VOTOS OBTENIDOS	
		SENADORES NACIONALES	DIPUTADOS NACIONALES
87	UNITE POR LA LIBERTAD Y LA DIGNIDAD	4	5
501	FRENTE AMPLIO PROGRESISTA	15	16
502	FRENTE DE IZQ. Y DE TRABAJADORES-UNIDAD	8	8
503	JUNTOS POR EL CAMBIO	135	135
504	PRIMERO SANTA FE	2	2
505	SOMOS FUTURO	7	7
506	PODEMOS	1	1
507	SOBERANIA POPULAR	6	6
508	FRENTE DE TODOS	94	92
VOTOS EN BLANCO (determinados por categoria)		5	5
VOTOS NULOS (determinados por categoria)		6	6
VOTOS RECURRIDOS (determinados por categoria)		—	—
VOTOS DE IDENTIDAD IMPUGNADA (en todas las columnas debe asentar la misma cantidad)		—	—
TOTAL DE VOTOS POR CATEGORIA		283	283

SR. PRESIDENTE DE MESA: LA SUMA DE LOS totales por columna (CATEGORIA) DEBE COINCIDIR CON LA CANTIDAD DE SOBRES UTILIZADOS QUE SE EXTRAJERON DE LA URNA

INFORMACION INDISPENSABLE PARA EL COBRO DE LA COMPENSACION-ART.72 DEL CODIGO ELECTORAL NACIONAL
(Por favor: COMPLETAR CON LETRA IMPRESA)

PRESIDENTE DE MESA		1º - VOCAL	
Apellidos y Nombres	Firma	Apellidos y Nombres	Firma
2º VOCAL		FISCALES PARTIDARIOS PRESENTES	
Apellidos y Nombres	Firma	Apellidos y Nombres	Firma

NO INTRODUCIR EN LA URNA - ENTREGAR AL AGENTE DE CORREOS

A.2. Ejemplo de telegrama mal cargado

El telegrama cargado corresponde a elecciones de concejales locales en vez de diputados o senadores nacionales.

DUPLICADO		(DEVOLVER EN LA URNA)		Nro Local: 31862		
		TELEGRAMA				
		Elecciones Generales - 14/11/2021				
		TRIBUNAL ELECTORAL DE LA PROVINCIA DE SANTA FE		1 de 1 Hoja		
Nº Mesa	00246	Sección	02	Círculo	368 A	CASILDA
Electores que votaron		Votos impugnados		Votantes observados 0		
Partido	Nro Lin	Concejales	Partido	Nro Lin	Concejales	
018 FRENTE PROGRESISTA CÍVICO Y SOCI	01	5				
025 FRENTE FEDERAL VIDA Y FAMILIA	02	1				
031 FRENTE DE TODOS	03	48				
068 FUERZA POPULAR CASILDENSE	04	24				
105 JUNTOS POR EL CAMBIO	05	89				
144 SANTA FE PARA TODOS	06	57				
DUPLICADO (DEVOLVER EN LA URNA)						
VOTOS AFIRMATIVOS EMITIDOS	80	247				
VOTOS EN BLANCO	81	8				
VOTOS NULOS	82	15				
VOTOS RECURRIDOS	83	—				
Presidente de mesa	Auxiliar de mesa		Auxiliar de mesa			
Firma:	Firma:		Firma:			
Aclaración: Gabriela Zafraín Nº de D.N.I.: 21416842	Aclaración: Martina Estebel Nº de D.N.I.: 44.02.2223		Aclaración: SENSACION BONICA Nº de D.N.I.: 2786254>			
FIRMA DE FISCALES ESCRUTINIO PROVISIONAL DE MESA						
Firma:	Firma:		Firma:			
Aclaración: 16.310 Alberto Nº de D.N.I.: 17.099.465	Aclaración: Nº de D.N.I.: 32.208.967		Aclaración: Nº de D.N.I.: 32.208.967			
Firma:	Firma:		Firma:			
Aclaración: Graciela Descantos Nº de D.N.I.: 12.222.680	Aclaración: Nº de D.N.I.: 12.222.680		Aclaración: Nº de D.N.I.: 12.222.680			
SUBDELEGADO						
Fecha/hora recepción - Firma						
MESA : 00246						

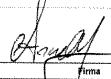
A.3. Ejemplo de telegrama con números sin espacio entre ellos

El telegrama no posee espacios entre los números, por lo que resulta complicado segmentarlos.

DESTINATARIO: CON COPIA: DIRECCION NACIONAL ELECTORAL		JUNTA ELECTORAL NACIONAL - Distrito - SANTA FE HOJA 1/1																																																															
DISTRITO SANTA FE	SECCION / CIRCUITO 2 - CASEROS 367 - BIGAND	MESA N°: 153																																																															
		ELECCIONES GENERALES - 14 DE NOVIEMBRE DE 2021 TELEGRAMA DEL PRESIDENTE DE MESA																																																															
CANTIDAD DE SOBRES UTILIZADOS EXTRAIDOS DE LA URNA		262																																																															
TOTAL DE ELECTORES QUE HAN VOTADO SEGUN EL PADRON		262																																																															
DIFERENCIA ENTRE LAS ANTERIORES		000																																																															
<table border="1"> <thead> <tr> <th>Nº</th> <th>Partido Político /Alianza</th> <th>CANTIDAD DE VOTOS OBTENIDOS</th> </tr> <tr> <th></th> <th></th> <th>SENADORES NACIONALES</th> <th>DIPUTADOS NACIONALES</th> </tr> </thead> <tbody> <tr> <td>87</td> <td>UNITE POR LA LIBERTAD Y LA DIGNIDAD</td> <td>006</td> <td>005</td> </tr> <tr> <td>501</td> <td>FRENTE AMPLIO PROGRESISTA</td> <td>027</td> <td>027</td> </tr> <tr> <td>502</td> <td>FRENTE DE IZQ. Y DE TRABAJADORES-UNIDAD</td> <td>003</td> <td>003</td> </tr> <tr> <td>503</td> <td>JUNTOS POR EL CAMBIO</td> <td>100</td> <td>101.</td> </tr> <tr> <td>504</td> <td>PRIMERO SANTA FE</td> <td>008</td> <td>008</td> </tr> <tr> <td>505</td> <td>SOMOS FUTURO</td> <td>005</td> <td>005</td> </tr> <tr> <td>506</td> <td>PODEMOS</td> <td>001</td> <td>001</td> </tr> <tr> <td>507</td> <td>SOBERANIA POPULAR</td> <td>011</td> <td>011</td> </tr> <tr> <td>508</td> <td>FRENTE DE TODOS</td> <td>087</td> <td>086</td> </tr> <tr> <td colspan="2">VOTOS EN BLANCO (discretinados por categoría)</td> <td>009</td> <td>009</td> </tr> <tr> <td colspan="2">VOTOS NULOS (discretinados por categoría)</td> <td>011</td> <td>012</td> </tr> <tr> <td colspan="2">VOTOS RECURRIDOS (discretinados por categoría)</td> <td>000</td> <td>000</td> </tr> <tr> <td colspan="2">VOTOS DE IDENTIDAD IMPUGNADA (en todos los cuadros debe asentir la misma cantidad)</td> <td>000</td> <td>000</td> </tr> <tr> <td colspan="2">TOTAL DE VOTOS POR CATEGORIA</td> <td>262</td> <td>262</td> </tr> </tbody> </table>			Nº	Partido Político /Alianza	CANTIDAD DE VOTOS OBTENIDOS			SENADORES NACIONALES	DIPUTADOS NACIONALES	87	UNITE POR LA LIBERTAD Y LA DIGNIDAD	006	005	501	FRENTE AMPLIO PROGRESISTA	027	027	502	FRENTE DE IZQ. Y DE TRABAJADORES-UNIDAD	003	003	503	JUNTOS POR EL CAMBIO	100	101.	504	PRIMERO SANTA FE	008	008	505	SOMOS FUTURO	005	005	506	PODEMOS	001	001	507	SOBERANIA POPULAR	011	011	508	FRENTE DE TODOS	087	086	VOTOS EN BLANCO (discretinados por categoría)		009	009	VOTOS NULOS (discretinados por categoría)		011	012	VOTOS RECURRIDOS (discretinados por categoría)		000	000	VOTOS DE IDENTIDAD IMPUGNADA (en todos los cuadros debe asentir la misma cantidad)		000	000	TOTAL DE VOTOS POR CATEGORIA		262	262
Nº	Partido Político /Alianza	CANTIDAD DE VOTOS OBTENIDOS																																																															
		SENADORES NACIONALES	DIPUTADOS NACIONALES																																																														
87	UNITE POR LA LIBERTAD Y LA DIGNIDAD	006	005																																																														
501	FRENTE AMPLIO PROGRESISTA	027	027																																																														
502	FRENTE DE IZQ. Y DE TRABAJADORES-UNIDAD	003	003																																																														
503	JUNTOS POR EL CAMBIO	100	101.																																																														
504	PRIMERO SANTA FE	008	008																																																														
505	SOMOS FUTURO	005	005																																																														
506	PODEMOS	001	001																																																														
507	SOBERANIA POPULAR	011	011																																																														
508	FRENTE DE TODOS	087	086																																																														
VOTOS EN BLANCO (discretinados por categoría)		009	009																																																														
VOTOS NULOS (discretinados por categoría)		011	012																																																														
VOTOS RECURRIDOS (discretinados por categoría)		000	000																																																														
VOTOS DE IDENTIDAD IMPUGNADA (en todos los cuadros debe asentir la misma cantidad)		000	000																																																														
TOTAL DE VOTOS POR CATEGORIA		262	262																																																														
SR. PRESIDENTE DE MESA: LA SUAÑA DE LOS TOTALES POR COLUMNA [CATEGORIA] DEBE COINCIDIR CON LA CANTIDAD DE SOBRES UTILIZADOS QUE SE EXTRAJERON DE LA URNA																																																																	
INFORMACION INDISPENSABLE PARA EL COBRO DE LA COMPENSACION-ART.72 DEL CODIGO ELECTORAL NACIONAL (Por favor: COMPLETAR CON LETRA IMPRESA)																																																																	
PRESIDENTE DE MESA Apellido y Nombres Firma N° Documento		1º VOCAL Apellido y Nombres Firma N° Documento																																																															
2º VOCAL Apellido y Nombres Firma N° Documento		FISCALES PARTIDARIOS PRESENTES Apellido y Nombres Firma N° Documento																																																															
NO INTRODUCIR EN LA URNA - ENTREGAR AL AGENTE DE CORREOS																																																																	

A.4. Ejemplo de telegrama con caracteres distintos a números

El telegrama no utiliza únicamente dígitos numéricos en la cantidad de votos.

 Correo Argentino		2100903008X0101
DESTINATARIO: CON COPIA: JUNTA ELECTORAL NACIONAL - Distrito - SANTA FE DIRECCION NACIONAL ELECTORAL		HOJA 1/1
DISTRITO SANTA FE	SECCION / CIRCUITO 9 - LA CAPITAL 20A - SANTO TOME	MESA N°: 3008
ELECCIONES GENERALES - 14 DE NOVIEMBRE DE 2021 TELEGRAMA DEL PRESIDENTE DE MESA		
CANTIDAD DE SOBRES UTILIZADOS EXTRADIDOS DE LA URNA 2 1 6		CANTIDAD DE VOTOS OBTENIDOS SENADORES NACIONALES DIPUTADOS NACIONALES
TOTAL DE ELECTORES QUE HAN VOTADO SEGUN EL PADRON 2 1 5		X 2 2 X 3 9
DIFERENCIA ENTRE LAS ANTERIORES X X X		X X X X X X
Nº Partido Político /Alianza		
87 UNITE POR LA LIBERTAD Y LA DIGNIDAD X 2 0 X 2 2		
501 FRENTE AMPLIO PROGRESISTA X 3 3 X 2 9		
502 FRENTE DE IZQ. Y DE TRABAJADORES-UNIDAD X X 5 X X 5		
503 JUNTOS POR EL CAMBIO X 7 9 X 8 1		
504 PRIMERO SANTA FE X X X X X X		
505 SOMOS FUTURO X X 4 X X 6		
506 PODEMOS X X 1 X X 1		
507 SOBERANIA POPULAR X X 6 X X 7		
508 FRENTE DE TODOS X 5 1 X 5 0		
VOTOS EN BLANCO (Incluidos por categoría) X X 6 X X 6		
VOTOS NULOS (Incluidos por categoría) X X 8 X X 9		
VOTOS RECURRIDOS (Incluidos por categoría) X X 7 X X 7		
VOTOS DE IDENTIDAD IMPUGNADA (en todas las columnas debe asentar la misma cantidad) X X X X X X		
TOTAL DE VOTOS POR CATEGORIA 2 0 2 2 0 1		
<small>SR. PRESIDENTE DE MESA: LA SUMA DE LOS TOTALES POR COLUMNAS (CATEGORIA) DEBE COINCIDIR CON LA CANTIDAD DE SOBRES UTILIZADOS QUE SE EXTRAJERON DE LA URNA</small>		
INFORMACION INDISPENSABLE PARA EL COBRO DE LA COMPENSACION- ART. 72 DEL CODIGO ELECTORAL NACIONAL <small>(Por favor, completar con letra imprenta)</small>		
PRESIDENTE DE MESA ARMANI LUCIA BELEN		
1º - VOCAL ANCIO MARINA SOI		
Apellido y Nombres  Firma	Apellido y Nombres  Firma	N° Documento 3154681160 N° Documento 4112561227
2º VOCAL ARCANGELO GLADYS		
Apellido y Nombres  Firma	Apellido y Nombres	N° Documento 38014438 N° Documento
FISCALES PARTIDARIOS PRESENTES		
NO INTRODUCIR EN LA URNA - ENTREGAR AL AGENTE DE CORREOS		

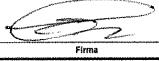
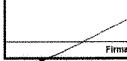
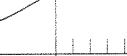
A.5. Ejemplo de telegrama ceros a la izquierda de la cantidad de votos

El telegrama posee ceros a la izquierda en la cantidad de votos, por lo que aumenta la probabilidad de predecir erróneamente la cantidad de votos.

 Correo Argentino		Barcode 2101304086X0101			
DESTINATARIO: CON COPIA: JUNTA ELECTORAL NACIONAL - Distrito - SANTA FE DIRECCION NACIONAL ELECTORAL		HOJA 1/1			
DISTRITO SANTA FE	SECCION / CIRCUITO 13 - ROSARIO 319 - ROSARIO SEC. 2A	MESA N°: 4086	ELECCIONES GENERALES - 14 DE NOVIEMBRE DE 2021 TELEGRAMA DEL PRESIDENTE DE MESA		
CANTIDAD DE SOBRES UTILIZADOS EXTRAIDOS DE LA URNA 2 6 8		TOTAL DE ELECTORES QUE HAN VOTADO SEGUN EL PADRON 2 6 8			
DIFERENCIA ENTRE LAS ANTERIORES 0 0 0					
N°	Partido Político / Alianza		CANTIDAD DE VOTOS OBTENIDOS		
			SENADORES NACIONALES	DIPUTADOS NACIONALES	
	87	UNITE POR LA LIBERTAD Y LA DIGNIDAD		0 0 5	0 0 7
	501	FRENTE AMPLIO PROGRESISTA		0 5 3	0 4 6
	502	FRENTE DE IZQ. Y DE TRABAJADORES-UNIDAD		0 0 2	0 0 2
	503	JUNTOS POR EL CAMBIO		1 4 4	1 4 6
	504	PRIMERO SANTA FE		0 0 6	0 0 3
	505	SOMOS FUTURO		0 0 0	0 0 0
	506	PODEMOS		0 0 1	0 0 2
	507	SOBERANIA POPULAR		0 0 7	0 1 9
508	FRENTE DE TODOS		0 3 7	0 3 0	
VOTOS EN BLANCO (distintivados por categoria)		0 0 7	0 0 7		
VOTOS NULOS (distintivados por categoria)		0 0 6	0 0 6		
VOTOS RECURRIDOS (distintivados por categoria)		0 0 0	0 0 0		
VOTOS DE IDENTIDAD IMPUGNADA (en todas las columnas debe escribir la misma cantidad)		0 0 0	0 0 0		
TOTAL DE VOTOS POR CATEGORIA		2 6 8	2 6 8		

SR. PRESIDENTE DE MESA: LA SUMA DE LOS TOTALES POR COLUMNA (CATEGORIA) DEBE COINCIDIR CON LA CANTIDAD DE SOBRES UTILIZADOS QUE SE EXTRAJERON DE LA URNA.

INFORMACION INDISPENSABLE PARA EL COBRO DE LA COMPENSACION - ART.72 DEL CODIGO ELECTORAL NACIONAL
(Por favor: COMPLETAR CON LETRA IMPRESA)

PRESIDENTE DE MESA PALACIO AGUSTINA Apellido y Nombres  31 26 97 34 N° Documento	1º - VOCAL Apellido y Nombres  Firma N° Documento
2º VOCAL Apellido y Nombres  Firma N° Documento	FISCALES PARTIDARIOS PRESENTES  Flavia Alcántara 35570 5223

NO INTRODUCIR EN LA URNA - ENTREGAR AL AGENTE DE CORREOS

Bibliografía

- Akiba, Takuya et al. (2019). «Optuna: A Next-generation Hyperparameter Optimization Framework». En: *Proceedings of the 25rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, págs. 2623-2631.
- Ben-David, Shai et al. (2006). «Analysis of Representations for Domain Adaptation». En: *Advances in Neural Information Processing Systems* 19.
- Bolelli, Federico et al. (2019). «Spaghetti labeling: Directed acyclic graphs for block-based connected components labeling». En: *IEEE Transactions on Image Processing* 29, págs. 1999-2012.
- Bradski, G. (2000). «The OpenCV Library». En: *Dr. Dobb's Journal of Software Tools*.
- Bugnon, Leandro A et al. (2020). «DL4papers: a deep learning approach for the automatic interpretation of scientific articles». En: *Bioinformatics* 36.11, págs. 3499-3506.
- Chen, Hanting et al. (2021). «Pre-Trained Image Processing Transformer». En: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, págs. 12299-12310.
- Chen, Xinyang et al. (2019). «Transferability vs. discriminability: Batch spectral penalization for adversarial domain adaptation». En: *International conference on machine learning*. PMLR, págs. 1081-1090.
- DeCoste, Dennis y Bernhard Schölkopf (2002). «Training invariant support vector machines». En: *Machine learning* 46.1, págs. 161-190.
- Erhan, Dumitru et al. (2010). «Why does unsupervised pre-training help deep learning?». En: *Proceedings of the thirteenth international conference on artificial intelligence and statistics*. JMLR Workshop y Conference Proceedings, págs. 201-208.
- Falcon, William y The PyTorch Lightning team (mar. de 2019). *PyTorch Lightning*. Ver. 1.4. DOI: 10.5281/zenodo.3828935. URL: <https://github.com/Lightning-AI/lightning>.
- Fukushima, Kunihiko (1980). «Neocognitron: A self-organizing neural network model for a mechanism of pattern recognition unaffected by shift in position». En: *Biological cybernetics* 36.4, págs. 193-202.
- Funahashi, Ken-Ichi (1989). «On the approximate realization of continuous mappings by neural networks». En: *Neural networks* 2.3, págs. 183-192.
- Ganin, Yaroslav et al. (2016). «Domain-adversarial training of neural networks». En: *The journal of machine learning research* 17.1, págs. 2096-2030.
- Girshick, Ross et al. (2014). «Rich feature hierarchies for accurate object detection and semantic segmentation». En: *Proceedings of the IEEE conference on computer vision and pattern recognition*, págs. 580-587.

- Glorot, Xavier, Antoine Bordes y Yoshua Bengio (2011). «Domain adaptation for large-scale sentiment classification: A deep learning approach». En: *ICML*, págs. 513-520.
- Gong, Boqing, Kristen Grauman y Fei Sha (2013). «Connecting the dots with landmarks: Discriminatively learning domain-invariant features for unsupervised domain adaptation». En: *International conference on machine learning*. PMLR, págs. 222-230.
- Goodfellow, Ian et al. (2020). «Generative adversarial networks». En: *Communications of the ACM* 63.11, págs. 139-144.
- Gretton, Arthur et al. (2012). «A kernel two-sample test». En: *The Journal of Machine Learning Research* 13.1, págs. 723-773.
- He, Kaiming et al. (2016). «Deep residual learning for image recognition». En: *Proceedings of the IEEE conference on computer vision and pattern recognition*, págs. 770-778.
- Hebb, Donald Olding (1949). *The organization of behavior. A neuropsychological theory*. Psychology press.
- Howard, Jeremy y Sebastian Ruder (2018). «Universal language model fine-tuning for text classification». En: *arXiv preprint arXiv:1801.06146*.
- Hubel, David H y Torsten N Wiesel (1959). «Receptive fields of single neurons in the cat's striate cortex». En: *The Journal of physiology* 148.3, pág. 574.
- Jiang, Junguang, Yang Shu y Mingsheng Long (2020). *Transfer Learning Library*. <https://github.com/thumt/Transfer-Learning-Library>.
- Jiang, Junguang et al. (2022). «Transferability in Deep Learning: A Survey». En: *arXiv preprint arXiv:2201.05867*.
- Krizhevsky, Alex, Ilya Sutskever y Geoffrey E Hinton (2017). «Imagenet classification with deep convolutional neural networks». En: *Communications of the ACM* 60.6, págs. 84-90.
- Lamagna, Walter Marcelo (2016). «Lectura artificial de números manuscritos en datos abiertos de elecciones legislativas en la Ciudad de Buenos Aires». Tesis doct. Universidad de Buenos Aires. Facultad de Ciencias Exactas y Naturales.
- Lauer, Fabien, Ching Y Suen y Gérard Bloch (2007). «A trainable feature extractor for handwritten digit recognition». En: *Pattern Recognition* 40.6, págs. 1816-1824.
- LeCun, Yann (1985). «A Learning Procedure for Assymetric Threshold Network». En: *Proceedings of Cognitiva 85*, págs. 599-604.
- LeCun, Yann, Yoshua Bengio y Geoffrey Hinton (2015). «Deep learning». En: *Nature* 521.7553, págs. 436-444.
- LeCun, Yann et al. (1989). «Backpropagation applied to handwritten zip code recognition». En: *Neural computation* 1.4, págs. 541-551.
- LeCun, Yann et al. (1995). «Learning algorithms for classification: A comparison on handwritten digit recognition». En: *Neural networks: the statistical mechanics perspective* 261.276, pág. 2.
- LeCun, Yann et al. (1998). «Gradient-based learning applied to document recognition». En: *Proceedings of the IEEE* 86.11, págs. 2278-2324.
- Lianza, Franco (2023). *OCR using Domain Adaptation*. <https://github.com/flianza/ocr-using-domain-adaptation>.

- Liu, Yang y Mirella Lapata (2019). «Text summarization with pretrained encoders». En: *arXiv preprint arXiv:1908.08345*.
- McCulloch, Warren S y Walter Pitts (1943). «A logical calculus of the ideas immanent in nervous activity». En: *The bulletin of mathematical biophysics* 5.4, págs. 115-133.
- McInnes, Leland, John Healy y James Melville (2018). «UMAP: Uniform manifold approximation and projection for dimension reduction». En: *arXiv preprint arXiv:1802.03426*.
- Minsky, Marvin y Seymour Papert (1969). «An introduction to computational geometry». En: *Cambridge tiass., HIT* 479, pág. 480.
- Paszke, Adam et al. (2019). «PyTorch: An Imperative Style, High-Performance Deep Learning Library». En: *Advances in Neural Information Processing Systems* 32. Ed. por H. Wallach et al. Curran Associates, Inc., págs. 8024-8035. URL: <http://papers.neurips.cc/paper/9015-pytorch-an-imperative-style-high-performance-deep-learning-library.pdf>.
- Peng, Xingchao et al. (2017). *VisDA: The Visual Domain Adaptation Challenge*. eprint: arXiv:1710.06924.
- Quinonero-Candela, Joaquin et al. (2008). *Dataset shift in machine learning*. Mit Press.
- Rosenblatt, Frank (1958). «The perceptron: a probabilistic model for information storage and organization in the brain.» En: *Psychological review* 65.6, pág. 386.
- Rumelhart, David E, Geoffrey E Hinton y Ronald J Williams (1986). «Learning representations by back-propagating errors». En: *Nature* 323.6088, págs. 533-536.
- Sandler, Mark et al. (2018). «MobileNetV2: Inverted Residuals and Linear Bottlenecks». En: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, págs. 4510-4520.
- Simonyan, Karen y Andrew Zisserman (2014). «Two-Stream Convolutional Networks for Action Recognition in Videos». En: *Advances in Neural Information Processing Systems*. Ed. por Z. Ghahramani et al. Vol. 27. Curran Associates, Inc., págs. 568-576. URL: <https://proceedings.neurips.cc/paper/2014/file/00ec53c4682d36f5c4359f4ae7bd7ba1-Paper.pdf>.
- Sugiyama, Masashi et al. (2007). «Direct importance estimation with model selection and its application to covariate shift adaptation». En: *Advances in neural information processing systems* 20, págs. 699-746.
- Sutskever, Ilya et al. (2013). «On the importance of initialization and momentum in deep learning». En: *International conference on machine learning*. PMLR, págs. 1139-1147.
- Suzuki, Satoshi et al. (1985). «Topological structural analysis of digitized binary images by border following». En: *Computer vision, graphics, and image processing* 30.1, págs. 32-46.
- Thrun, Sebastian y Lorien Pratt (1998). *Learning to learn*. Springer.
- Tzeng, Eric et al. (2017). «Adversarial Discriminative Domain Adaptation». En: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, págs. 7167-7176.

- Viehmann, Thomas, Luca Antiga y Alessia Marcolini (2021). *TorchDrift*. <https://github.com/torchdrift/torchdrift/>.
- Wang, Dayong et al. (2016). «Deep learning for identifying metastatic breast cancer». En: *arXiv preprint arXiv:1606.05718*.
- Werbos, Paul (1974). «Beyond regression: new tools for prediction and analysis in the behavioral sciences». En: *Ph. D. dissertation, Harvard University*.
- Xie, Saining et al. (2017). «Aggregated Residual Transformations for Deep Neural Networks». En: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, págs. 1492-1500.
- Xu, Ruijia et al. (2019). «Larger norm more transferable: An adaptive feature norm approach for unsupervised domain adaptation». En: *Proceedings of the IEEE/CVF International Conference on Computer Vision*, págs. 1426-1435.
- Yosinski, Jason et al. (2014). «How transferable are features in deep neural networks?» En: *Advances in neural information processing systems 27*, págs. 3320-3328.
- Zhang, Yuchen et al. (2019). «Bridging theory and algorithm for domain adaptation». En: *International Conference on Machine Learning*. PMLR, págs. 7404-7413.